

Problemas de Optimización Convexa

Capítulo 4 — Boyd & Vandenberghe

Optimización Convexa — MM-520

11 de junio de 2026

Esquema del capítulo

Problema de optimización matemática

Forma estándar

$$\begin{array}{ll}\text{minimizar} & f_0(x) \\ \text{sujeto a} & f_i(x) \leq b_i, \quad i = 1, \dots, m\end{array}$$

- $x = (x_1, \dots, x_n) \in \mathbb{R}^n$: *variables de optimización* (o de decisión).
- $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$: *función objetivo* (o de costo).
- $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$: *funciones de restricción*.
- b_i : *límite o cota* de la restricción i .

Óptimo


El vector x^* es *óptimo* si tiene el menor valor de f_0 entre todos los vectores que satisfacen las restricciones.

$$\begin{array}{ll}\text{minimizar} & f_0(x) \\ \text{sujeto a} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_j(x) = 0, \quad j = 1, \dots, p\end{array}$$

- Restricciones de desigualdad e igualdad se reescalan con la cota.
- Solución: $f_0(x^*) = \inf\{f_0(x) : f_i(x) \leq 0, h_j(x) = 0\}$.

Óptimo local vs. global

- x^* **óptimo local**: $\exists R > 0$ tal que $f_0(x^*) \leq f_0(x)$ para todo factible con $\|x - x^*\|_2 \leq R$.
- **Global**: vale para *todo* x factible.
- En general: óptimo global $\Rightarrow$ local, pero no al revés.



Conjunto factible y región de nivel

Conjunto factible

$$\mathcal{D} = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{j=1}^p \text{dom } h_j.$$

Óptimo se busca sobre $\mathcal{D}$.

Subnivel

Para $t \in \mathbb{R}$:

$$f_0^{-1}((-\infty, t]) = \{x \in \text{dom } f_0 : f_0(x) \leq t\}.$$

x^* óptimo global $\Leftrightarrow$ el subnivel en $f_0(x^*)$ toca $\mathcal{D}$.

- ❶ **Óptimo global** (x^*).
- ❷ **Óptimo local**.
- ❸ **Óptimo local “estricto”**: $\exists R > 0$ tal que $f_0(x^*) < f_0(x)$ para todo factible, $0 < \|x - x^*\|_2 \leq R$.
 - Una función estrictamente decreciente sobre un dominio acotado: óptimo en un vértice.
 - Problemas *no convexos* pueden tener óptimos locales no globales.

Problema de optimización convexa (POC)

Forma estándar

$$\begin{array}{ll}\text{minimizar} & f_0(x) \\ \text{sujeto a} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & a_j^\top x = b_j, \quad j = 1, \dots, p\end{array}$$

con $f_0, f_1, \dots, f_m$ **convexas**.


- Restricciones de igualdad *afines* (necesario para convexidad).
- $\text{dom } f_i$ son conjuntos convexos (en general: $\mathbb{R}^n$ si f_i es diferenciable con Hessiano $\succeq 0$).

El conjunto factible convexo

El conjunto factible de un POC *siempre es convexo*:

$$\mathcal{C} = \{x \in \mathbb{R}^n : f_i(x) \leq 0, a_j^\top x = b_j\}.$$

- Subniveles de funciones convexas son convexos.
- Hiperplanos $\{a^\top x = b\}$ son convexos.
- Intersección de convexos = convexo.



Propiedad clave: óptimo local = global

Theorem (POC)

Para un problema de optimización convexa, todo óptimo local es óptimo global.

Esquema de la prueba. Supongamos x^* local y $\tilde{x}$ factible con $f_0(\tilde{x}) < f_0(x^*)$. Para $\theta \in (0, 1]$ el punto

$$x_\theta = x^* + \theta(\tilde{x} - x^*)$$

es factible (convexidad) y

$$f_0(x_\theta) \leq (1 - \theta)f_0(x^*) + \theta f_0(\tilde{x}) < f_0(x^*).$$

Tomando $\theta \rightarrow 0$ contradice la optimalidad local.



Diferenciabilidad

Si f_0 es diferenciable y convexa, una condición suficiente para optimalidad global es:

$$\nabla f_0(x^*)^\top (x - x^*) \geq 0 \quad \forall x \in \mathcal{C}.$$

- Interpretación: ninguna dirección factible decrece f_0 en x^* .
- Si $\mathcal{C} = \mathbb{R}^n$, equivale a $\nabla f_0(x^*) = 0$.

Problema lineal (LP)

Forma estándar

$$\begin{array}{ll}\text{minimizar} & c^T x + c_0 \\ \text{sujeto a} & Gx \preceq h, \quad Ax = b\end{array}$$


- Función objetivo y restricciones son **afines** (caso particular de convexo).
- Conjunto factible = **poliedro** (intersección de semiespacios e hiperplanos).
- Variables en $\mathbb{R}^n$; en algunas variantes $x \succeq 0$.

Poliedro: $\mathcal{P} = \{x : Gx \preceq h, Ax = b\}$.

- $G \in \mathbb{R}^{m \times n}$, $A \in \mathbb{R}^{p \times n}$.
- G puede “incluir” la identidad para imponer cotas.

Forma estándar:

$$\begin{array}{ll} \text{mín. } c^\top x \\ \text{s.a. } Ax = b, x \succeq 0. \end{array}$$



Transformaciones equivalentes

- Restricción de igualdad: $Ax = b \Leftrightarrow$ dos desigualdades $Ax \leq b$ y $Ax \geq b$.
- Variable libre: $x = x^+ - x^-$ con $x^+, x^- \geq 0$.
- Minimizar $c^\top x =$ maximizar $(-c)^\top x$.
- Inequivalencia “estricta” $a^\top x < b$ se puede sustituir por $a^\top x \leq b - \epsilon$ con $\epsilon > 0$ prefijado.

Ejemplo: planificación de producción

Una fábrica produce 3 productos. Beneficios por unidad: $c = (3, 1, 2)$. Recursos y consumo por unidad:

$$A = \begin{pmatrix} 1 & 2 & 1 \\ 3 & 0 & 2 \end{pmatrix}, \quad b = \begin{pmatrix} 4 \\ 6 \end{pmatrix}, \quad x \geq 0.$$

$$\begin{aligned} &\text{máx. } c^T x \\ &\text{s.a. } Ax \leq b, \quad x \geq 0. \end{aligned}$$

Solución en un vértice del poliedro factible.


Problema cuadrático (QP)

Forma estándar

$$\begin{array}{ll} \text{minimizar} & (1/2) \mathbf{x}^\top \mathbf{P} \mathbf{x} + \mathbf{q}^\top \mathbf{x} + r \\ \text{sujeto a} & \mathbf{G} \mathbf{x} \preceq \mathbf{h}, \quad \mathbf{A} \mathbf{x} = \mathbf{b} \end{array}$$

- $\mathbf{P} \in \mathbb{S}_+^n$ *simétrica definida no-negativa* (para convexidad).
- Función objetivo es cuadrática estrictamente convexa si $\mathbf{P} \succ 0$.
- LP = QP con $\mathbf{P} = 0$.

Diagrama de QP convexo



QP con restricciones lineales Límite natural entre LP y convexo general.

ℓ_2 -regularización (ridge) mín $\|Ax - b\|_2^2 + \lambda\|x\|_2^2$: caso $P = 2(A^\top A + \lambda I)$.

Control óptimo LQR Estado $x_{t+1} = A_t x_t + B_t u_t$; costo $\sum x_t^\top Q x_t + u_t^\top R u_t$.

SVM con kernel cuadrático mín $\|w\|^2$ s.a. restricciones lineales de margen.

Forma posinomial (GP)

Una función $f : \mathbb{R}_{++}^n \rightarrow \mathbb{R}$ es **posinomial** si existe $c_k > 0$ y $a_{kj} \in \mathbb{R}$ tales que

$$f(x) = \sum_{k=1}^K c_k x_1^{a_{k1}} x_2^{a_{k2}} \cdots x_n^{a_{kn}}.$$

- Cada *monomio* $c_k x^a$ con exponentes reales cualesquiera.
- Suma de monomios con coeficientes positivos.

Forma monomial y el problema GP

Monomial

$$f(x) = c x_1^{a_1} x_2^{a_2} \cdots x_n^{a_n} \text{ con } c > 0.$$

Programa geométrico

$$\begin{array}{ll} \text{minimizar} & f_0(x) \\ \text{sujeto a} & f_i(x) \leq 1, \quad i = 1, \dots, m, \\ & h_j(x) = 1, \quad j = 1, \dots, p \end{array}$$

con $f_0, \dots, f_m$ posinomiales y $h_1, \dots, h_p$ monomiales.

GP no es convexo — pero su cambio de variables sí

Sustituir $y_i = \log x_i$, $b_{kj} = \log c_k$ y $\tilde{f}(y) = \log f(x)$:

- Monomios: $\log(c x^a) = \log c + a^\top y$ (afín en y).
- Posinomiales: $\log(\sum_k c_k x^{a_k})$ es **log-sum-exp** — *convexa*.

GP en variable x $\longleftrightarrow$ **Problema convexo** en variable $y = \log x$.

Ejemplo clásico: mínimo de posinomio

$$\begin{aligned} \min_{x>0} \quad & x^{-1}y^{-1/2}z^{-1} + 2,3 x y^2 z + 5 x^{1/2}y \\ \text{s.a.} \quad & (1/3)x^{-2}y^{-2} + (4/3)y^{1/2}z^{-1} \leq 1, \quad x + y \leq 1. \end{aligned}$$

El cambio $y_1 = \log x$, $y_2 = \log y$, $y_3 = \log z$ lo convierte en un problema convexo resoluble eficientemente.

Definition

Un cono $K \subseteq \mathbb{R}^m$ es **propio** si:

- K es convexo.
 - K es cerrado.
 - K tiene interior no vacío.
 - $K \cap (-K) = \{0\}$.
-
- K define un orden parcial: $y \preceq_K z \Leftrightarrow z - y \in K$.
 - Ejemplos: $\mathbb{R}_+^m$ (cono no-negativo), S_+^m (matrices semidefinidas positivas).

$$\begin{array}{ll}\text{minimizar} & f_0(x) \\ \text{sujeto a} & f_i(x) \preceq_{K_i} 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0\end{array}$$

- $f_i : \mathbb{R}^n \rightarrow \mathbb{R}^{m_i}$, $K_i \subseteq \mathbb{R}^{m_i}$ cono propio.
- Conexión con desigualdades estándar: $K_i = \mathbb{R}_+^{m_i}$ recupera $f_i(x) \leq 0$.

Cono dual

$$K^* = \{y : y^\top x \geq 0 \ \forall x \in K\}.$$

- $\mathbb{R}_+^m$: dual = $\mathbb{R}_+^m$ (autodual).
- S_+^m : dual = S_+^m (autodual).
- Cono de Lorentz (segundo orden): $\mathcal{L}_m = \{(x, t) : \|x\|_2 \leq t\}$; dual $\mathcal{L}_m^* = \mathcal{L}_m$.

Ejemplo: SDP (programa semidefinido)

$$\begin{array}{ll}\text{minimizar} & c^\top x \\ \text{sujeto a} & x_1 F_1 + \cdots + x_n F_n + G \preceq_{S_+^m} 0 \\ & Ax = b\end{array}$$

- $F_i, G \in S^m$ matrices simétricas.
- Es un POC con $K_i = S_+^m$.
- Generaliza LP ($S_+^1 \cong \mathbb{R}_+$) y muchos QP.

Problema vectorial (VOP)

$$\begin{array}{ll} \text{minimizar} & (f_1(x), \dots, f_q(x)) \\ \text{sujeto a} & x \in \mathcal{C} \end{array}$$

- Varios objetivos **en conflicto** $\Rightarrow$ no hay un único “mejor”.
- La teoría: *óptimo de Pareto* (Pareto-óptimo) — un vector no dominado.

Óptimo de Pareto y débilmente Pareto

Definition (Pareto-óptimo)

$x^* \in \mathcal{C}$ es *Pareto-óptimo* si no existe $x \in \mathcal{C}$ con $f_i(x) \leq f_i(x^*)$ para todo i y alguna desigualdad estricta.

Definition (Débil)

x^* es *débilmente Pareto* si no existe $x \in \mathcal{C}$ con $f_i(x) < f_i(x^*)$ para todo i .

Ponderación escalar (método de pesos)

Fijar $\lambda \succ 0$, $\sum \lambda_i = 1$, y resolver


$$\min_{x \in \mathcal{C}} \lambda^\top f(x) = \sum_{i=1}^q \lambda_i f_i(x).$$

- Si x_λ^* es único $\Rightarrow$ Pareto-óptimo.
- Si x_λ^* es Pareto-óptimo para todo $\lambda \succ 0$ y el problema es convexo, la curva de trade-off se reconstruye.
- No todos los Pareto-óptimos se obtienen con un único λ .

Imagen: frente de Pareto



Mapa general de problemas convexos



- ❶ **POC** = minimizar convexa, restricciones convexas e iguales afines.
- ❷ **Óptimo local = global** (y por tanto, los algoritmos encuentran la mejor solución posible).
- ❸ **LP, QP, GP, SOCP, SDP** son casos particulares, todos resolubles eficiente y confiablemente.
- ❹ **GP** se vuelve convexo con el cambio $y = \log x$.
- ❺ **Desigualdades generalizadas** extienden $\text{LP} \rightarrow \text{SDP}$ vía conos propios.
- ❻ **Optimización vectorial** se reduce a múltiples escalares (ponderación), produciendo el *frente de Pareto*.

-  S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004.
stanford.edu/~boyd/cvxbook/
-  S. Boyd y L. Vandenberghe. *Notes for EE364B — Convex Optimization II*. Stanford.
-  Yu. Nesterov y A. Nemirovski. *Interior-Point Polynomial Algorithms in Convex Programming*. SIAM, 1994.
-  A. Ben-Tal y A. Nemirovski. *Lectures on Modern Convex Optimization*. SIAM, 2001.