

Minimización sin Restricciones

Capítulo 9 — Boyd & Vandenberghe

Optimización Convexa — MM-520

15 de junio de 2026

Esquema del capítulo

- 1 Esquema del capítulo
- 2 El problema de minimización sin restricciones
- 3 Algoritmos de descenso
- 4 Descenso por gradiente
- 5 Máximo descenso (steepest descent)
- 6 Método de Newton
- 7 Autoconcordancia
- 8 Implementación
- 9 Resumen

9.1 El problema

Problema

$$\min_{x \in \mathbb{R}^n} f(x)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es *dos veces continuamente diferenciable* ($f \in \mathcal{C}^2$), y el dominio $\text{dom } f$ es **todo** $\mathbb{R}^n$ (o abierto y la función se extiende suavemente).

- **Óptimo global:** x^* con $f(x^*) \leq f(x)$ para todo x .
- **Óptimo local:** $f(x) \geq f(x^*)$ para x en un entorno de x^* .
- **Condición necesaria** (1^{er} orden): si x^* es local y f diferenciable,

$$\nabla f(x^*) = 0.$$

- **Condición suficiente** (2.^o orden): si $\nabla f(x^*) = 0$ y $\nabla^2 f(x^*) \succ 0$ (definida positiva), entonces x^* es *estricto* local.

9.1 Ejemplo: cuadrática diagonal


Example

$f(x) = \frac{1}{2}(x_1^2 + \gamma x_2^2)$ con $\gamma > 0$.

$$\nabla f(x) = \begin{pmatrix} x_1 \\ \gamma x_2 \end{pmatrix}, \quad \nabla^2 f(x) = \begin{pmatrix} 1 & 0 \\ 0 & \gamma \end{pmatrix}.$$

El único punto crítico es $x^* = (0,0)$ y la Hessiana es definida positiva, así que x^* es un **mínimo global estricto**.

- Si $\gamma \gg 1$: *valle estrecho* (mal condicionado).
- Si $\gamma = 1$: contornos circulares (bien condicionado).



9.2 Algoritmos de descenso (descenso por línea)

Idea general

Construir una sucesión $x^{(k)}$ que converge a un óptimo eligiendo, en cada paso, una *dirección de descenso* Δx y un *tamaño de paso* $t > 0$:

$$x^{(k+1)} = x^{(k)} + t^{(k)} \Delta x^{(k)}.$$

Definition (Dirección de descenso)

Δx es de descenso en x si $\nabla f(x)^\top \Delta x < 0$. Equiv.: existe $t_0 > 0$ con $f(x + t\Delta x) < f(x)$ para todo $t \in (0, t_0)$.

- Toda dirección que forma ángulo obtuso con $-\nabla f(x)$ es de descenso.
- Tres familias clásicas: **descenso por gradiente**, **máximo descenso**, **Newton**.

9.2 Cono de direcciones de descenso


Geometría

El conjunto de direcciones de descenso en x es un **cono abierto**:

$$\mathcal{D}(x) = \{\Delta x \in \mathbb{R}^n : \nabla f(x)^\top \Delta x < 0\}.$$

Es el semiplano abierto que contiene a $-\nabla f(x)$ y está separado por la *hiperplano tangente* $\{\Delta x : \nabla f(x)^\top \Delta x = 0\}$.

- Toda dirección con ángulo obtuso respecto a $-\nabla f(x)$ es de descenso.
- Cuanto más cerca de $-\nabla f(x)$ (en ángulo), mayor la razón de decrecimiento $\frac{\nabla f^\top \Delta x}{\|\Delta x\|}$.




9.2 Búsqueda de línea (*line search*)

Elegir t a lo largo de la dirección Δx :

- **Búsqueda exacta:** $t = \arg \min_{s \geq 0} f(x + s\Delta x)$. Requiere resolver un problema 1-D; caro.
- **Búsqueda por retroceso (Armijo):** empezar en $t = 1$ y reducir por un factor $\beta \in (0, 1)$ hasta que

$$f(x + t\Delta x) \leq f(x) + \alpha t \nabla f(x)^\top \Delta x, \quad \alpha \in (0, 1/2), \beta \in (0, 1).$$

La línea recta de la derecha acota la condición.



9.3 Descenso por gradiente (*gradient descent*)

Método

Tomar $\Delta x = -\nabla f(x)$ (dirección del *máximo descenso local*):

$$x^{(k+1)} = x^{(k)} - t^{(k)} \nabla f(x^{(k)}).$$


- Es la elección más natural, pero el paso t es *crítico*: si es muy grande, el método diverge; si es muy pequeño, converge muy lento.
- **Criterio de paro:** usualmente $\|\nabla f(x)\|_2 \leq \epsilon$.
- Cuesta $\mathcal{O}(n)$ por iteración (sólo requiere el gradiente).

Example

Cuadrática $f(x) = \frac{1}{2}(x_1^2 + \gamma x_2^2)$ con $\gamma \gg 1$: con búsqueda exacta aparece el **zigzag** (los ejes están mal escalados).


9.3 Comportamiento: bien vs. mal condicionado

Bien condicionado ($\gamma = 1$)



Convergencia rápida y monótona.

Mal condicionado ($\gamma = 10$)



Zig-zag: muchos pasos pequeños.

Cuadrática $f(x) = \frac{1}{2}(x_1^2 + \gamma x_2^2)$ con búsqueda exacta. Pasos siempre ortogonales a los anteriores (gradiente conjugado en 2D, pero la convergencia es *sublineal* en general).

9.3 Convergencia del descenso por gradiente

Theorem (Velocidad lineal)

Si f es **convexa** y de **Lipschitz con constante** L en su gradiente (∇f es L -Lipschitz), entonces con paso $t \leq 1/L$ se cumple

$$f(x^{(k)}) - p^* \leq \frac{\|x^{(0)} - x^*\|_2^2}{2 t k}.$$

Si además f es m -fuertemente convexa, la convergencia es **lineal**:

$$f(x^{(k)}) - p^* \leq c^k (f(x^{(0)}) - p^*), \quad c < 1.$$

- El factor c depende de la *razón de condición* $\kappa = L/m$.
- Mal condicionamiento (κ grande) $\Rightarrow$ zig-zag y convergencia muy lenta.

9.4 Método del máximo descenso


Dirección normalizada

Dada una norma $\|\cdot\|$, la dirección de máximo descenso en x es

$$\Delta x_{\text{nsd}} = \arg \min_{\|v\|=1} \nabla f(x)^\top v.$$

Con $\|\cdot\|_2$, $\Delta x_{\text{nsd}} = -\nabla f(x)$ y se recupera el descenso por gradiente.

- **Con $\|\cdot\|_1$:** el método elige una *coordenada* i con $|\partial f / \partial x_i| = \|\nabla f(x)\|_\infty$ y se mueve en $-e_i$ (o $+e_i$ según el signo).
- **Con $\|\cdot\|_\infty$:** Δx_{nsd} es un vector con componentes $-\text{sgn}(\partial f / \partial x_i)$.
- Todas estas normas son **invariantes bajo escalado**: reescalar las coordenadas no cambia la dirección.




9.4 Ejemplo: máximo descenso con $\|\cdot\|_\infty$

Example

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 2x_2^2), \quad x = (2, 1), \quad \nabla f(x) = (2, 2).$$

$$\Delta x_{\text{nsd}} = -\text{sgn}(\nabla f(x)) = (-1, -1).$$

Interpretación: en cada paso se mueve una unidad a lo largo de un eje de coordenadas — en 2D esto da 4 pasos en zig-zag desde $(2, 1)$ hasta $(0, 0)$.



9.5 Método de Newton

Construcción

En x , aproximar f por su desarrollo de Taylor de 2.º orden:

$$\hat{f}(x + v) = f(x) + \nabla f(x)^\top v + \frac{1}{2} v^\top \nabla^2 f(x) v.$$

Minimizando $\hat{f}$ (asumiendo $\nabla^2 f(x) \succ 0$) se obtiene la **dirección de Newton**:


$$\Delta x_{\text{nt}} = -\nabla^2 f(x)^{-1} \nabla f(x).$$

El paso es $x^+ = x + t \Delta x_{\text{nt}}$, con t elegido por búsqueda de línea.

- **Paso puro** de Newton ($t = 1$) es óptimo cerca del óptimo.
- **Decremento de Newton**: $\lambda(x) = (\nabla f(x)^\top \nabla^2 f(x)^{-1} \nabla f(x))^{1/2}$. Sirve como criterio de paro ($\lambda^2/2 \leq \epsilon$).

9.5 Dirección de Newton: geometría


- La dirección de Newton en x apunta al *mínimo de la aproximación cuadrática* de f alrededor de x .
- Para una cuadrática exacta, ese mínimo es x^* : un solo paso de Newton ($t = 1$) resuelve el problema.
- En general, $\Delta_{x_{nt}}$ apunta al **centro del elipsoide** de nivel $\{v : \nabla f^\top v + \frac{1}{2} v^\top \nabla^2 f v = 0\}$, no necesariamente al óptimo.



En cada iteración, Newton minimiza el modelo cuadrático local de f para obtener el siguiente punto.


9.5 Gradiente vs. Newton en un valle estrecho

Descenso por gradiente



Muchos pasos: zig-zag, tasa lineal.

Método de Newton



Un solo paso resuelve la cuadrática.

Cuadrática mal condicionada: Newton es *invariante afín*, gradiente no.

9.5 Convergencia del método de Newton

Theorem (Convergencia local cuadrática)

Sea $f \in \mathcal{C}^3$ y x^* con $\nabla^2 f(x^*) \succ 0$. Entonces $x^{(k)}$ generado por Newton ($t = 1$) converge a x^* si $x^{(0)}$ está suficientemente cerca, y

$$\|x^{(k+1)} - x^*\|_2 \leq c \|x^{(k)} - x^*\|_2^2.$$

- **Ventaja:** convergencia muy rápida (cuadrática) cerca del óptimo.
- **Desventaja:** cada paso cuesta $\mathcal{O}(n^3)$ (resolver sistema lineal) y construye la Hessiana.
- *Sin Hessiana exacta:* Newton-CG, L-BFGS, etc. resuelven $\nabla^2 f(x) \Delta x = -\nabla f(x)$ aproximadamente.

9.6 Funciones auto-concordantes — motivación

Problema

La convergencia cuadrática de Newton requiere estar cerca del óptimo, pero *¿qué tan cerca?* y *¿cómo afecta* el escalamiento de f ?

- El análisis clásico usa m y L de la Hessiana, que *no son invariantes* bajo transformaciones afines de x .
- La **auto-concordancia** (Nesterov–Nemirovski) es una propiedad que **sí** es invariante bajo cambio afín de variable.
- Permite cuantificar el número de iteraciones de Newton de forma independiente del escalamiento del problema.

9.6 Ejemplo: $f(x) = -\log x$ es auto-concordante

Para $f(x) = -\log x$ en $(0, \infty)$:

$$f'(x) = -1/x,$$

$$f''(x) = 1/x^2,$$


$$f'''(x) = -2/x^3.$$

Verificamos la desigualdad:

$$|f'''(x)| = \frac{2}{x^3} \leq 2 \left(\frac{1}{x^2} \right)^{3/2} = 2 f''(x)^{3/2}.$$

Igualmente, $f(x) = -\log(-x)$ en $(-\infty, 0)$.

f'' cambia rápidamente cerca de la frontera del dominio: por eso el método de Newton debe *dar pasos amortiguados* cerca de la frontera.



9.6 Definición (funciones $\mathbb{R} \rightarrow \mathbb{R}$)

Definition (Auto-concordante)

Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ tres veces diferenciable. Decimos que f es *auto-concordante* en un intervalo $C \subseteq \text{dom } f$ si

$$|f'''(x)| \leq 2 f''(x)^{3/2} \quad \text{para todo } x \in C.$$

- Si la desigualdad vale en C y f es convexa, f se extiende a una función auto-concordante en todo su dominio.
- **Ejemplos:** $f(x) = -\log x$ en $(0, \infty)$ y $f(x) = -\log(-x)$ en $(-\infty, 0)$.

9.6 Definición general ($f : \mathbb{R}^n \rightarrow \mathbb{R}$)

Definition (Auto-concordante en $\mathbb{R}^n$)

f es *auto-concordante* en un conjunto convexo abierto C si para todo $x \in C$ y toda dirección h , la restricción $\varphi(t) = f(x + th)$ satisface

$$|\varphi'''(0)| \leq 2 \varphi''(0)^{3/2}.$$

Theorem (Acotaciones de la Hessiana)

Si f es auto-concordante y $\delta = (h^\top \nabla^2 f(x) h)^{1/2} < 1$, entonces

$$(1 - \delta)^2 \nabla^2 f(x) \preceq \nabla^2 f(x + h) \preceq \frac{1}{(1 - \delta)^2} \nabla^2 f(x).$$

- La cantidad $\delta = \|h\|_x$ es la **norma local** inducida por $\nabla^2 f(x)$.

9.6 Complejidad de Newton

Theorem (Conteo de iteraciones)

Sea f auto-concordante con $\nabla^2 f \succ 0$ y sea $x^{(0)}$ con $\|x^{(0)} - x^*\|_{x^{(0)}} \leq 1$. Entonces Newton con paso amortiguado $t = 1$ converge a x^* y el número de iteraciones para alcanzar $\lambda(x) \leq \epsilon$ es

$$\mathcal{O}(\log \log(1/\epsilon)).$$

- Esta cota es *invariante* bajo reescalamientos afines: depende sólo de ϵ , no de constantes de la Hessiana.
- A diferencia del teorema clásico de Newton (cuadrática, *local*), aquí se obtiene un conteo global gracias a la auto-concordancia.

9.7 Implementación de los métodos de descenso

Esquema general

- 1 Dado x , calcular f , ∇f y (si es Newton) $\nabla^2 f$.
- 2 Determinar una dirección de descenso Δx .
- 3 Elegir t por búsqueda de línea (exacta o por retroceso).
- 4 Actualizar $x \leftarrow x + t\Delta x$.
- 5 Repetir hasta $\|\nabla f(x)\| \leq \epsilon$ o $\lambda(x) \leq \epsilon$.

9.7 Detalles prácticos

- **Gradiente vs. Newton:** gradiente es $\mathcal{O}(n)$ por iteración pero converge lineal; Newton es $\mathcal{O}(n^3)$ pero converge cuadráticamente.
- **Newton sin Hessiana exacta:** métodos cuasi-Newton (BFGS, L-BFGS) aproximan $\nabla^2 f$ usando diferencias de gradientes — prácticos en dimensiones altas.
- **Búsqueda de línea:** usar *retroceso* (Armijo) salvo que se tenga una razón clara para búsqueda exacta (e.g. cuadráticas).
- **Criterio de paro:** $\|\nabla f(x)\|_2 \leq \epsilon$ es invariante bajo escalado; $f(x^{(k)}) - f(x^{(k-1)}) \leq \epsilon$ no lo es.
- **Condicionamiento:** mal condicionado $\kappa = L/m$ grande ralentiza el descenso por gradiente — preconditionar o usar Newton.

9.7 Tabla comparativa

Método	Costo / iter.	Convergencia	Global	Local
Gradiente	$\mathcal{O}(n)$	lineal c^k con $c \approx (\kappa - 1)/(\kappa + 1)$	sí	sí
Newton	$\mathcal{O}(n^3)$	cuadrática local	no (sin amortiguam.)	sí
Newton amortiguado	$\mathcal{O}(n^3)$	cuadrática local	sí (búsqueda de línea)	sí
Cuasi-Newton (BFGS)	$\mathcal{O}(n^2)$	superlineal	sí	sí
Newton + auto-concord.	$\mathcal{O}(n^3)$	$\mathcal{O}(\log \log(1/\epsilon))$	sí	sí

$\kappa = L/m$ es la razón de condición de $\nabla^2 f$ en el óptimo.

Método	Características
Descenso por gradiente	$t \leq 1/L$; simple; convergencia lineal; zig-zag si mal condicionado.
Máximo descenso Newton	Usa $\ \cdot\ $ distinta de ℓ_2 ; invariante al escalado. Usa Hessiana; convergencia <i>cuadrática local</i> ; caro $\mathcal{O}(n^3)$.
Auto-concordancia	Propiedad invariante; garantiza convergencia global de Newton en $\mathcal{O}(\log \log(1/\epsilon))$ iteraciones.

- S. Boyd and L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004. **Capítulo 9: Unconstrained minimization.**
- Apuntes de clase y *slides* del curso EE364a, Stanford University.
- Y. Nesterov and A. Nemirovskii, *Interior-Point Polynomial Algorithms in Convex Programming*, SIAM, 1994 (auto-concordancia).

Fin de la presentación.