

Aproximación y Proyección Geométrica

Boyd & Vandenberghe — Capítulos 6 y 8

Optimización Convexa — MM-520

20 de julio de 2026

Esquema

- 1 Esquema del capítulo
- 2 Aproximación por norma y mínima norma
- 3 Aproximación regularizada
- 4 Aproximación paramétrica de distribuciones
- 5 Una aplicación clásica: optimización de portafolios (Markowitz)
- 6 Aproximación no paramétrica de distribuciones
- 7 Proyección sobre un conjunto convexo
- 8 Distancia entre conjuntos y separación
- 9 Resumen

Aproximación: motivación

Modelo lineal de medición

$$y = Ax + v, \quad A \in \mathbb{R}^{m \times n}, \quad x \in \mathbb{R}^n, \quad v \in \mathbb{R}^m.$$

- y : medición observada; v : error de medición.
- “Implausibilidad” del error: una **norma** $\|v\|$.
- Dada la medición $y = b$, el valor de x más plausible es el que minimiza $\|Ax - b\|$.

Problema de aproximación por norma

$$\text{minimizar} \quad \|Ax - b\| \quad (P_{\text{norm}})$$

con $\|\cdot\|$ cualquier norma de $\mathbb{R}^m$.

Forma primal: introduciendo las variables de residuo

Reemplazando $r = Ax - b$, el problema (P_{norm}) se reescribe como un **LP / QP según la norma**:

$$\begin{array}{ll} \text{minimizar} & \|r\| \\ \text{sujeto a} & r = Ax - b. \end{array}$$

- Variable de decisión extendida: $(x, r) \in \mathbb{R}^{n+m}$.
- Restricción lineal de igualdad: $r - Ax = -b$.
- La estructura del problema depende sólo de la norma de r .

Lecturas frecuentes: geometría, estimación y diseño

Tres lecturas equivalentes de (P_{norm}) según el contexto:

- 1 **Aproximación geométrica.** Ax^* es el punto del *recorrido* $\mathcal{R}(A) \subset \mathbb{R}^m$ más cercano a b en la norma $\|\cdot\|$.
- 2 **Estimación.** Dados $y = b$ en el modelo $y = Ax + v$, el x^* más plausible según $\|v\|$.
- 3 **Diseño óptimo.** x son variables de diseño, Ax el resultado producido; x^* aproxima mejor el resultado deseado b .



[imagen aquí]

Figura: las tres lecturas equivalentes de la aproximación por norma.

Descripción: ilustrar $b \in \mathbb{R}^m$, el recorrido $\mathcal{R}(A)$ como subespacio afín, y Ax^* como el punto de $\mathcal{R}(A)$ más cercano a b .

Ejemplo 1: aproximación euclidiana (ℓ_2)

Norma: $\|\cdot\| = \|\cdot\|_2$. Problema:

$$\text{minimizar } \frac{1}{2} \|Ax - b\|_2^2.$$

- **Condiciones de optimalidad:** $A^\top(Ax - b) = 0$ — las *ecuaciones normales*.
- **Solución analítica:** $x^* = A^\dagger b = (A^\top A)^{-1} A^\top b$ cuando A tiene rango completo por columnas.
- **En general:** $x^* = A^\dagger b$, con $A^\dagger$ la *pseudoinversa* de Moore–Penrose.

Equivale al clásico problema de *mínimos cuadrados*.

Ejemplo 2: aproximación *Chebyshev* / *minimax* (ℓ_∞)

Norma: $\|\cdot\|_\infty = \max_i |r_i|$. Problema:

$$\text{minimizar} \quad \max_{i=1,\dots,m} |a_i^\top x - b_i| \quad (\text{con } a_i^\top \text{ la } i\text{-ésima fila de } A).$$

Formulación como LP: introducir t que acota las desviaciones:

$$\begin{array}{ll} \text{minimizar} & t \\ \text{sujeito a} & -t \mathbf{1} \preceq A\mathbf{x} - \mathbf{b} \preceq t \mathbf{1}. \end{array}$$

- Variables: $(\mathbf{x}, t) \in \mathbb{R}^{n+1}$. Restricciones: $2m$ desigualdades lineales.
- $\mathbf{x}^*$ minimiza el *peor* residuo absoluto.

Ejemplo 3: suma de residuos absolutos (ℓ_1)

Norma: $\|\cdot\|_1 = \sum_i |r_i|$. Problema:

$$\text{minimizar } \|Ax - b\|_1.$$

Formulación como LP: introducir $y \in \mathbb{R}_+^m$, $y \succeq r$, $y \succeq -r$:

$$\begin{array}{ll}\text{minimizar} & 1^\top y \\ \text{sujeto a} & -y \preceq Ax - b \preceq y.\end{array}$$

- ℓ_1 favorece soluciones con **algunos** residuos grandes y el resto exactamente en 0 (*sparsity* en los residuos).
- Robusto frente a valores atípicos comparado con ℓ_2 .

Problema

$$\begin{array}{ll} \text{minimizar} & \|x\| \\ \text{sujeeto a} & Ax = b. \end{array}$$

(P_{LN} , least-norm)

- *Dual* (en cierto sentido) del problema de aproximación por norma: intercambia el rol de x y del residuo $Ax - b$.
- Factible cuando $b \in \mathcal{R}(A)$.
- Geométricamente: x^* es el punto del conjunto afín $\{x \mid Ax = b\}$ más cercano a 0 en la norma $\|\cdot\|$.

Mínima norma: solución

Si A tiene rango completo por filas ($m \geq n$, $\text{rank}(A) = n$):

$$x^* = A^\top (AA^\top)^{-1}b = A^\dagger b.$$

En general, la solución del problema de mínima norma es

$$x = A^\dagger b + (I - A^\dagger A)z, \quad z \in \mathbb{R}^n \text{ arbitrario.}$$

- $(I - A^\dagger A)$ es la *proyección ortogonal* sobre el espacio nulo de A .
- La **única** solución de mínima norma se obtiene tomando $z = 0$.

Recuérdese:

$A^\dagger = A^\top (AA^\top)^{-1}$ si A rango completo por filas;
 $A^\dagger = (A^\top A)^{-1}A^\top$ si A rango completo por columnas.

Resumen comparativo: las dos caras del mismo cuadro

	Aproximación (sobre $\ \cdot\ $)	Mínima norma (sobre $\ \cdot\ $)
Problema	$\min_x \ Ax - b\ $	$\min_x \ x\ \text{ s.a. } Ax = b$
Rol de x	ajustar el modelo	ser “lo más pequeño posible”
Rol de $Ax - b$	residuo a minimizar	debe anularse
Solución (ℓ_2)	$A^\dagger b$	$A^\top (AA^\top)^{-1} b$

Idea unificadora

Por dualidad, los dos problemas son intercambiables: minimizar la norma de un lado es maximizar/dual al otro. La geometría es la misma, sólo cambia el papel de cada variable.

¿Por qué regularizar?

En la práctica $Ax = b$ raramente es soluble, o $A^\top A$ está mal condicionada y $x^\star = (A^\top A)^{-1} A^\top b$ explota.

- **Sobre-ajuste:** LS puro se ajusta al ruido de b y pierde poder de generalización.
- **Multicolinealidad:** con $A^\top A$ singular o casi, $A^\dagger$ amplifica errores.
- **Mal condicionamiento:** $\kappa(A^\top A) = \kappa(A)^2 \gg 1$.

Idea central

Añadir al objetivo un **término de penalización** $\lambda R(x)$ que “empuje” a x hacia un comportamiento deseado (pequeño, disperso, suave...).

Regularización de Tikhonov (ℓ_2)

$$\begin{aligned} \text{minimizar} \quad & \|Ax - b\|_2^2 + \lambda \|x\|_2^2 \\ & \lambda > 0 \text{ (parámetro de regularización)}. \end{aligned}$$

- $\lambda \rightarrow 0$: recupera mínimos cuadrados.
- $\lambda \rightarrow \infty$: domina el segundo término, $x^* \rightarrow 0$.
- **Condiciones de optimalidad:** $(A^\top A + \lambda I)x = A^\top b$.
- **Solución:** $x^* = (A^\top A + \lambda I)^{-1} A^\top b$.
- Resuelve el mal condicionamiento *siempre* ($A^\top A + \lambda I \succ 0$).

Nombres clásicos

Estadística: *ridge regression*. Visión por computador y reconstrucción de imágenes: *Tikhonov*.

Otras penalizaciones frecuentes

Nombre	Objetivo	Efecto
Ridge / Tikhonov	$\ Ax - b\ ^2 + \lambda \ x\ _2^2$	x pequeño global
Lasso	$\ Ax - b\ ^2 + \lambda \ x\ _1$	x disperso (sparse)
Elastic net	$\ Ax - b\ ^2 + \alpha \ x\ _2^2 + \beta \ x\ _1$	disperso + estable
Total variation	$\ Ax - b\ ^2 + \lambda \text{TV}(x)$	x suave a trozos

- **Selection de λ :** validación cruzada, cota sobre $\|x\|$, discrepancia (Morozov), curvas-L.
- **Forma en norma:** cualquier $\phi(x)$ convexa, monótona en $\|x\|$, entrega un regularizador.

Ajuste por función de penalización: (P_ϕ)

En lugar de una norma, se puede usar una *función de penalización*:

$$\begin{array}{ll} \text{minimizar} & \phi(r_1) + \cdots + \phi(r_m) \\ \text{sujeto a} & r = Ax - b. \end{array} \quad (P_\phi)$$

con $\phi : \mathbb{R} \rightarrow \mathbb{R}$ **convexa**. Tres elecciones clásicas:

$$\begin{array}{ll} \phi(u) = u^2 & \text{(cuadrática, sensible a outliers),} \\ \phi(u) = \max\{0, |u| - a\} & \text{(deadzone-lineal: ignora } |u| \leq a), \\ \phi(u) = \begin{cases} -(a^2/2) \log(1 - (u/a)^2) & |u| < a, \\ +\infty & |u| \geq a \end{cases} & \text{(log-barrera: fuerza } |u| < a). \end{array}$$

La forma de ϕ controla la *distribución* del residuo.

[imagen aquí]

Supuesto

Los datos $x_1, \dots, x_n \in \mathbb{R}$ son i.i.d. según una densidad

$$p(x; \theta), \quad \theta \in \Theta \subset \mathbb{R}^p.$$

La *familia paramétrica* $\{p(\cdot; \theta)\}_{\theta \in \Theta}$ es conocida salvo el valor de θ .

- *Ejemplos:* Gaussiana $\mathcal{N}(\mu, \sigma^2)$, exponencial $\text{Exp}(\lambda)$, Bernoulli, Poisson, mezcla finita.
- **Objetivo:** a partir de los datos, estimar θ .

Estimación por máxima verosimilitud (ML)

Función de verosimilitud y log-verosimilitud

$$L(\theta) = \prod_{i=1}^n p(x_i; \theta), \quad \ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log p(x_i; \theta).$$

- El estimador de máxima verosimilitud (ML/MLE) es $\theta_{\text{ML}} = \arg \max_{\theta} L(\theta) = \arg \min_{\theta} -\ell(\theta)$.
- $-\ell$ es *suma de funciones* de la densidad $p(\cdot; \theta)$ en cada dato: encaja como un problema de *penalización* (P_{ϕ}).


Caso Gaussiano

Con $p(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x-\mu)^2/(2\sigma^2)}$, $\theta = (\mu, \sigma^2)$ y el negativo de la log-verosimilitud

$$-\ell(\mu, \sigma^2) = \frac{1}{2\sigma^2} \sum_i (x_i - \mu)^2 + \frac{n}{2} \log(2\pi\sigma^2),$$

cuya minimización da $\hat{\mu} = \frac{1}{n} \sum_i x_i$ y $\hat{\sigma}^2 = \frac{1}{n} \sum_i (x_i - \hat{\mu})^2$.

Ejemplo discreto: MLE para una $Poisson(\lambda)$



$n = 1000$ muestras i.i.d. de $Poisson(\lambda^* = 4)$; $\hat{\lambda}_{MLE} = \bar{x} = 3,958 \approx 4$. De $\lambda \in \{1, 12\}$ sólo $\lambda = 4 = \hat{\lambda}_{MLE}$ ajusta el histograma.

Estimación MAP = aproximación regularizada

Estimador MAP (máximo a posteriori)

$$\theta_{\text{MAP}} = \arg \max_{\theta} \underbrace{p(\theta)}_{\text{priori}} \cdot \underbrace{p(x_1, \dots, x_n | \theta)}_{\text{verosimilitud}} = \arg \min_{\theta} [-\log p(x; \theta)] + [-\log p(\theta)].$$

- Es la **fusión de dos ingredientes convexos**: likelihood y priori.
- **Caso clave**: priori Gaussiano $\theta \sim \mathcal{N}(0, \tau^2 I) \Rightarrow -\log p(\theta) = \frac{1}{2\tau^2} \|\theta\|_2^2 + \text{cte.}$ MAP = *Tikhonov* con $\lambda = 1/\tau^2$.


Re-encuadre como problema convexo

ML: $\min_{\theta} -\sum_i \log p(x_i; \theta)$.

MAP: $\min_{\theta} -\sum_i \log p(x_i; \theta) + \Omega(\theta)$ (penalización por la priori).

Motivación con datos reales: dos rutas para comprar USD

- En la práctica hay **dos activos** para hacerse de USD en Honduras: la compra *bancaria* (precio estable, LPS Dólar –Compra / –Venta) y la compra *vía P2P* con USDT (precio de mercado, volátil, USDT P2P–Mejor venta).
- Pregunta natural: ¿cuándo conviene cada ruta? ¿Se pueden mezclar para mejorar el *precio efectivo*?
- Es exactamente el problema de Markowitz: dos activos correlacionados con perfiles distintos de retorno esperado (μ) y riesgo (Σ).
- Los datos (ago 2025 – jul 2026) muestran: el banco es estable pero caro, el P2P es más barato en media pero mucho más volátil. Combinarlos reduce varianza sin sacrificar precio promedio.



Motivación: diversificación y riesgo

- Un inversionista elige pesos $w_i \geq 0$ sobre n activos con retornos aleatorios r_i , $\sum_i w_i = 1$ (cartera autofinanciada).
- Retorno y riesgo del portafolio (asumiendo retornos independientes del período):

$$R(w) = \mu^\top w, \quad \sigma^2(w) = w^\top \Sigma w,$$

con $\mu \in \mathbb{R}^n$ los retornos esperados y $\Sigma \succ 0$ la matriz de covarianzas.

- **Idea clave de Markowitz (1952):** la varianza del portafolio es menor que el promedio ponderado de las varianzas individuales, siempre que los activos no estén perfectamente correlacionados.

$$\sigma^2(w) = \sum_i w_i^2 \sigma_i^2 + \sum_{i \neq j} w_i w_j \sigma_{ij} < \sum_i w_i \sigma_i^2 \quad (\text{si } \sigma_{ij} < 0 \text{ para algún par}).$$

- Por tanto se puede *reducir el riesgo sin sacrificar rendimiento esperado*, eligiendo pesos que exploten la covarianza.

El modelo de media–varianza (Markowitz, 1952)

Datos: $\mu \in \mathbb{R}^n$, $\Sigma \in \mathbb{R}^{n \times n}$ ($\Sigma \succ 0$), presupuesto $W = 1$, restricción de no–venta corta opcional $w \geq 0$ (o $\geq -w_{\text{máx}}$, etc.).

$$(P_{\text{MV}}) \quad \begin{array}{ll} \min_{w \in \mathbb{R}^n} & w^\top \Sigma w \\ \text{s.t.} & \mu^\top w \geq R_{\text{mín}}, \\ & 1^\top w = 1. \end{array}$$

Variantes equivalentes (todas convexas):

- Minimizar $\sigma^2(w)$ para una *rentabilidad objetivo* $R_{\text{mín}}$.
- Maximizar $\mu^\top w - \lambda w^\top \Sigma w$ para $\lambda > 0$ dado (aversión al riesgo).
- Minimizar $\sigma^2(w)$ en la *forma estándar* de QP

$$\begin{array}{ll} \min_w & w^\top \Sigma w \\ \text{s.t.} & Aw = b, \quad Gw \leq h \end{array}$$

que es *exactamente* un problema de la familia (QP) de Boyd–Vandenberghe.

Relación con lo anterior

La forma dual de (P_{MV}) es una *aproximación regularizada* (Tikhonov) sobre los retornos:

$\min_w \|\Sigma^{1/2} w\|^2$ controlado por μ — el mismo aparato convexo de ℓ_2 y ϕ .

Frontera eficiente

- Al resolver (P_{MV}) para cada valor de $R_{\min} \in [\mu_{\min}, \mu_{\max}]$ se obtiene la **frontera eficiente**: el conjunto de portafolios con menor varianza para cada nivel de retorno esperado.
- En el plano (σ, R) la frontera es una hipérbola que abre hacia la derecha (las dos ramas superior e inferior son simétricas; sólo la superior es eficiente).
- **Capital Market Line (CML)**: al añadir un activo libre de riesgo con retorno r_f , la mejor combinación se obtiene en la recta tangente a la frontera que pasa por $(0, r_f)$:

$$R_P = r_f + \frac{\mu_M - r_f}{\sigma_M} \sigma_P.$$

- La pendiente $(\mu_M - r_f)/\sigma_M$ es el *precio de mercado del riesgo*.

**[esquema: (σ, R) con
frontera eficiente
y CML]**

Convexidad y resolución

- (P_{MV}) es un **QP convexo**:
 - objetivo: forma cuadrática $w^T \Sigma w$ con $\Sigma \succ 0 \Rightarrow$ fuertemente convexa;
 - restricciones: lineales (afines) $\Rightarrow$ conjunto factible convexo.
- *Por tanto* existe un único óptimo y los KKT son *suficientes*. Se resuelve en milisegundos con métodos de punto interior para n moderado ($\sim 10^3$ activos).
- Markowitz desarrolló el **método de la línea crítica** (1956), un algoritmo de programación cuadrática que traza toda la frontera eficiente cambiando $R_{\min}$ entre restricciones activas.
- Métodos generales aplicables: gradiente proyectado, Newton truncado, *ADMM* para problemas separables, solvers de barrera modernos.

Críticas conocidas (y por qué importa la convexidad)

- *Error maximization*: pequeños errores en $\hat{\mu}$, $\hat{\Sigma}$ producen cambios enormes en w^* .
- Sin $w \geq 0$, la solución puede ser altamente apalancada (largos en unos activos, cortos en otros); en la práctica se impone $w \geq 0$ (o cotas por posición).
- La covarianza empírica subestima las correlaciones reales en crisis; alternativas: shrinkage (Ledoit–Wolf), Black–Litterman, jerarquía de riesgo (HRP).

Estimación no paramétrica: idea

- **No asumimos una forma paramétrica** $p(x; \theta)$.
- Objetivo: estimar la densidad $p(x)$ en cada x (o una función desconocida $f : \mathbb{R} \rightarrow \mathbb{R}$) *sólo* a partir de datos, sin conocimiento previo de su forma.
- Toda la información está en los datos: “*let the data speak*”.

Resumen de los tres métodos que veremos

- 1 Estimación por *histogramas*.
- 2 Estimación por *kernel* (KDE).
- 3 Estimación por *k-vecinos más cercanos* (k -NN).

Dividir el rango en M celdas de ancho h y contar cuántos datos caen en cada una.

$$\hat{p}_{\text{hist}}(x) = \frac{1}{nh} \#\{i \mid x_i \text{ cae en la celda que contiene } x\}.$$

- **Ventaja:** extremadamente simple, rápida.
- **Desventaja:** discontinua en los bordes de celda, depende de M y de dónde se cortan las celdas.
- Elección del ancho h : sesgo vs. varianza (ancho pequeño $\rightarrow$ alta varianza; ancho grande $\rightarrow$ alto sesgo).

Estimador de Parzen–Rosenblatt

$$\hat{p}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$

donde $K : \mathbb{R} \rightarrow \mathbb{R}_+$ es un *kernel* (e.g. Gaussiano, Epanechnikov, triangular, uniforme) con $\int K = 1$.

- *Intuición*: poner una “campana” K sobre cada dato y promediar.
- Continuidad y suavidad heredadas de K .
- **Ancho de banda** h : controla el tradeoff sesgo/varianza — usualmente $h \propto n^{-1/5}$ para datos en 1D.

Estimación por k -vecinos más cercanos

Idea: estimar la densidad en x por la *frecuencia local* alrededor de x , medida con la métrica de los k vecinos más próximos.

$$\hat{p}(x) = \frac{k/n}{\text{vol}(B(x, r(x)))}, \quad r(x) = \text{distancia al } k\text{-ésimo vecino más cercano de } x.$$

- *Análoga en clasificación*: asignar a x la clase mayoritaria de sus k vecinos más cercanos.
- **Ventaja**: no asume forma para la densidad; “adaptativa” (en regiones con pocos datos, r crece).
- **Costo**: requiere k -NN queries — $O(n \log n)$ con árboles (KD-trees, ball-trees), $O(nd)$ lineales.

Proyección euclidiana de x_0 sobre C

$$\Pi_C(x_0) = \arg \min_{x \in C} \frac{1}{2} \|x - x_0\|_2^2.$$

- Si C es **convexo cerrado** no vacío, el problema tiene *única* solución (convexidad + función objetivo estrictamente convexa).
- Si $C = \emptyset$: no hay proyección. Si C no convexo: la proyección puede no ser única o no existir.

Caracterización variacional de la proyección

$x^* = \Pi_C(x_0)$ si y sólo si se cumple la **condición variacional**:

$$(x_0 - x^*)^\top (x - x^*) \leq 0 \quad \forall x \in C.$$

- Lectura geométrica: el vector $x^* - x_0$ es *normal* a C en el punto x^* , apuntando hacia adentro.
- Equivale a decir que $x_0 - x^*$ pertenece al cono normal $N_C(x^*)$.

Consecuencia clave

La condición variacional es el análogo convexo de las *condiciones KKT* para problemas con un único conjunto factible convexo.

Ejemplos clásicos de proyección

- ❶ **Hiperplano** $H = \{x \mid a^\top x = b\}$:

$$\Pi_H(x_0) = x_0 + \frac{b - a^\top x_0}{\|a\|_2^2} a.$$

- ❷ **Half-space** $H^- = \{x \mid a^\top x \leq b\}$: $\Pi_{H^-}(x_0)$ = proyección sobre H si $a^\top x_0 \leq b$; en otro caso $= x_0 + \frac{b - a^\top x_0}{\|a\|_2^2} a$.

- ❸ **Bola euclidiana** $B = \{c\} \oplus r\mathbb{B}$:

$$\Pi_B(x_0) = \begin{cases} x_0 & \text{si } \|x_0 - c\|_2 \leq r, \\ c + r \frac{x_0 - c}{\|x_0 - c\|_2} & \text{si } \|x_0 - c\|_2 > r. \end{cases}$$

- ❹ **Caja** $C = \{x \mid l \preceq x \preceq u\}$: $\Pi_C(x_0)$ se aplica coordenada a coordenada, $[\Pi_C(x_0)]_i = \min(u_i, \max(l_i, x_{0,i}))$.

Proyección sobre conos y la PSD

- **Cono K :** la proyección sobre un cono convexo cerrado K satisface $\Pi_K(x_0) = (x_0 - \Pi_{K^*}(x_0))$ (descomposición de Moreau).
- **Cono no negativo $K = \mathbb{R}_+^n$:** $\Pi_{\mathbb{R}_+^n}(x_0)$ recorta a 0 las coordenadas negativas.
- **Cono PSD $\mathcal{S}_+^n = \{S \mid S = S^\top, S \succeq 0\}$:** la proyección euclidiana de x_0 sobre $\mathcal{S}_+^n$ es $V \text{diag}(\lambda_+) V^\top$, donde $x_0 = V \text{diag}(\lambda) V^\top$ es la descomposición propia y $\lambda_+ = \max(\lambda, 0)$.
- **Cajas y poliedros:** en general la proyección sobre un poliedro se reduce a un QP (cuadrático convexo).

Distancia euclidiana entre C y D

$$\text{dist}(C, D) = \min_{x \in C, y \in D} \|x - y\|_2.$$

- Si C y D son *convexos compactos* no vacíos, la mínima distancia se alcanza y es positiva si y sólo si $C \cap D = \emptyset$.
- **Equivalencia de Weber:** $\text{dist}(C, D) > 0$ si y sólo si existe un *hiperplano separador estricto* entre C y D .

La distancia se reformula como un **QP**:

$$\begin{array}{ll} \text{minimizar} & t \\ \text{sujeto a} & x \in C, y \in D, \|x - y\|_2 \leq t. \end{array}$$

- Útil cuando C, D están dados por conos o desigualdades: los conjuntos quedan como restricciones lineales/MI.
- Si C, D son **poliedros**: la distancia es un LP o un *second-order cone program* (SOCP).
- Si C, D son **elipsoides**: la distancia se reduce a un *problema de SDP*.

Hiperplano separador y teoremas de separación

Theorem (Separación estándar, B&V §2.5.1)

Si $C, D \subset \mathbb{R}^n$ son conjuntos convexos con intersección vacía, existen $a \neq 0$ y b tales que

$$a^\top x \leq b \quad \forall x \in C, \quad a^\top y \geq b \quad \forall y \in D.$$

Theorem (Separación estricta, B&V §2.5.2)

Si C, D son convexos cerrados no vacíos con intersección vacía y uno de ellos es compacto, existe $a \neq 0$, $b_1 < b_2$ con

$$a^\top x \leq b_1 \quad \forall x \in C, \quad a^\top y \geq b_2 \quad \forall y \in D.$$

Aplicaciones

Detección de factibilidad/infactibilidad, separación en clasificadores (SVM), verificación geométrica, condicionamiento.

- ❶ **Aproximación por norma** (B&V §6.1): $\min \|Ax - b\|$. Tres casos clásicos: ℓ_2 (cuadrática, pseudoinversa), ℓ_∞ (LP, *minimax*), ℓ_1 (LP, robusto a outliers).
- ❷ **Mínima norma** (B&V §6.2): $\min \|x\|$ s.a. $Ax = b$. Solución $A^\dagger b$ en el ℓ_2 , freedom $\ker A$ en general.
- ❸ **Aproximación regularizada** (B&V §6.4/§6.5): Tikhonov $\min \|Ax - b\|^2 + \lambda \|x\|^2$, solución $(A^\top A + \lambda I)^{-1} A^\top b$. Otras: Lasso, TV.
- ❹ **Aproximación paramétrica** (B&V §6.6): ML, MAP = ML + priori = regularización Tikhonov cuando $\theta \sim \mathcal{N}(0, \tau^2 I)$.
- ❺ **Aproximación no paramétrica** (B&V §6.6): histogramas, KDE ($h \propto n^{-1/5}$), k -NN.
- ❻ **Proyección** (B&V §8.1): $\Pi_C(x_0)$ única en C convexo cerrado; variacional $\Leftrightarrow$ KKT. Recetas explícitas para hiperplanos, bolas, cajas, conos, PSD.
- ❼ **Distancia / separación** (B&V §8.2): QP si poliedros; existencia garantizada de hiperplano separador (estricto si uno es compacto).

Referencias

-  S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. stanford.edu/~boyd/cvxbook/ (libro completo, PDF libre).
-  S. Boyd y L. Vandenberghe. *EE364A Slides*. Stanford, 2023.
-  A. N. Tikhonov y V. Ya. Arsenin. *Solutions of Ill-Posed Problems*. Winston, 1977.
-  R. Tibshirani. Regression shrinkage and selection via the lasso. *J. Royal Stat. Soc. B* 58(1):267–288, 1996.
-  T. Hastie, R. Tibshirani, J. Friedman. *The Elements of Statistical Learning*. Springer, 2nd ed., 2009.
-  H. Markowitz. Portfolio selection. *Journal of Finance* 7(1):77–91, 1952.
-  *Markowitz model*. Wikipedia.
en.wikipedia.org/wiki/Markowitz_model.
-  *Portfolio optimization*. Wikipedia.
en.wikipedia.org/wiki/Portfolio_optimization.