

# Aproximación y Proyección Geométrica

Boyd & Vandenberghe — Capítulos 6 y 8

Optimización Convexa — MM-520

13 de julio de 2026

# Esquema

- 1 Esquema del capítulo
- 2 Aproximación por norma y mínima norma
- 3 Aproximación regularizada
- 4 Aproximación paramétrica de distribuciones
- 5 Aproximación no paramétrica de distribuciones
- 6 Proyección sobre un conjunto convexo
- 7 Distancia entre conjuntos y separación
- 8 Resumen

# Aproximación: motivación

## Modelo lineal de medición

$$y = Ax + v, \quad A \in \mathbb{R}^{m \times n}, \quad x \in \mathbb{R}^n, \quad v \in \mathbb{R}^m.$$

- $y$ : medición observada;  $v$ : error de medición.
- “Implausibilidad” del error: una **norma**  $\|v\|$ .
- Dada la medición  $y = b$ , el valor de  $x$  más plausible es el que minimiza  $\|Ax - b\|$ .

## Problema de aproximación por norma

$$\text{minimizar} \quad \|Ax - b\| \quad (P_{\text{norm}})$$

con  $\|\cdot\|$  cualquier norma de  $\mathbb{R}^m$ .

# Forma primal: introduciendo las variables de residuo

Reemplazando  $r = Ax - b$ , el problema  $(P_{\text{norm}})$  se reescribe como un **LP / QP según la norma**:

$$\begin{array}{ll}\text{minimizar} & \|r\| \\ \text{sujeto a} & r = Ax - b.\end{array}$$

- Variable de decisión extendida:  $(x, r) \in \mathbb{R}^{n+m}$ .
- Restricción lineal de igualdad:  $r - Ax = -b$ .
- La estructura del problema depende sólo de la norma de  $r$ .

Tres lecturas equivalentes de  $(P_{\text{norm}})$  según el contexto:

- 1 **Aproximación geométrica.**  $Ax^*$  es el punto del *recorrido*  $\mathcal{R}(A) \subset \mathbb{R}^m$  más cercano a  $b$  en la norma  $\|\cdot\|$ .
- 2 **Estimación.** Dados  $y = b$  en el modelo  $y = Ax + v$ , el  $x^*$  más plausible según  $\|v\|$ .
- 3 **Diseño óptimo.**  $x$  son variables de diseño,  $Ax$  el resultado producido;  $x^*$  aproxima mejor el resultado deseado  $b$ .

## Ejemplo 1: aproximación euclidiana ( $\ell_2$ )

Norma:  $\|\cdot\| = \|\cdot\|_2$ . Problema:

$$\text{minimizar } \frac{1}{2} \|Ax - b\|_2^2.$$

- **Condiciones de optimalidad:**  $A^\top(Ax - b) = 0$  — las *ecuaciones normales*.
- **Solución analítica:**  $x^* = A^\dagger b = (A^\top A)^{-1} A^\top b$  cuando  $A$  tiene rango completo por columnas.
- **En general:**  $x^* = A^\dagger b$ , con  $A^\dagger$  la *pseudoinversa* de Moore–Penrose.

Equivale al clásico problema de *mínimos cuadrados*.

## Ejemplo 2: aproximación *Chebyshev* / *minimax* ( $\ell_\infty$ )

Norma:  $\|\cdot\|_\infty = \max_i |r_i|$ . Problema:

$$\text{minimizar} \quad \max_{i=1,\dots,m} |a_i^\top x - b_i| \quad (\text{con } a_i^\top \text{ la } i\text{-ésima fila de } A).$$

**Formulación como LP:** introducir  $t$  que acota las desviaciones:

$$\begin{array}{ll} \text{minimizar} & t \\ \text{sujeto a} & -t \mathbf{1} \preceq Ax - b \preceq t \mathbf{1}. \end{array}$$

- Variables:  $(x, t) \in \mathbb{R}^{n+1}$ . Restricciones:  $2m$  desigualdades lineales.
- $x^*$  minimiza el *peor* residuo absoluto.

## Ejemplo 3: suma de residuos absolutos ( $\ell_1$ )

Norma:  $\|\cdot\|_1 = \sum_i |r_i|$ . Problema:

$$\text{minimizar } \|Ax - b\|_1.$$

**Formulación como LP:** introducir  $y \in \mathbb{R}_+^m$ ,  $y \succeq r$ ,  $y \succeq -r$ :

$$\begin{array}{ll}\text{minimizar} & 1^\top y \\ \text{sujeto a} & -y \preceq Ax - b \preceq y.\end{array}$$

- $\ell_1$  favorece soluciones con **algunos** residuos grandes y el resto exactamente en 0 (*sparsity* en los residuos).
- Robusto frente a valores atípicos comparado con  $\ell_2$ .



# Aproximación por mínima norma: definición

## Problema

$$\begin{array}{ll} \text{minimizar} & \|x\| \\ \text{sujeto a} & Ax = b. \end{array}$$

(P<sub>LN</sub>, least-norm)

- *Dual* (en cierto sentido) del problema de aproximación por norma: mira  $b$  como dato y  $x$  como a minimizar. residuo  $Ax - b$ .
- Factible cuando  $b \in \mathcal{R}(A)$ .
- Geométricamente:  $x^*$  es el punto del conjunto afín  $\{x \mid Ax = b\}$  más cercano a 0 en la norma  $\|\cdot\|$ .

## Mínima norma: solución

Si  $A$  tiene rango completo por filas ( $m \geq n$ ,  $\text{rank}(A) = n$ ):

$$x^* = A^\top (AA^\top)^{-1}b = A^\dagger b.$$

En general, la solución del problema de mínima norma es

$$x = A^\dagger b + (I - A^\dagger A)z, \quad z \in \mathbb{R}^n \text{ arbitrario.}$$

- $(I - A^\dagger A)$  es la *proyección ortogonal* sobre el espacio nulo de  $A$ .
- La **única** solución de mínima norma se obtiene tomando  $z = 0$ .

Recuérdese:

$A^\dagger = A^\top (AA^\top)^{-1}$  si  $A$  rango completo por filas;  
 $A^\dagger = (A^\top A)^{-1}A^\top$  si  $A$  rango completo por columnas.

## Resumen comparativo: las dos caras del mismo cuadro

|                       | <b>Aproximación</b><br>(sobre $\  \cdot \ $ ) | <b>Mínima norma</b><br>(sobre $\  \cdot \ $ ) |
|-----------------------|-----------------------------------------------|-----------------------------------------------|
| Problema              | $\min_x \ Ax - b\ $                           | $\min_x \ x\  \text{ s.a. } Ax = b$           |
| Rol de $x$            | ajustar el modelo                             | ser “lo más pequeño posible”                  |
| Rol de $Ax - b$       | residuo a minimizar                           | debe anularse                                 |
| Solución ( $\ell_2$ ) | $A^\dagger b$                                 | $A^\top (AA^\top)^{-1} b$                     |

### Idea unificadora

Por dualidad, los dos problemas son intercambiables: minimizar la norma de un lado es maximizar/dual al otro. La geometría es la misma, sólo cambia el papel de cada variable.

# ¿Por qué regularizar?

En la práctica  $Ax = b$  raramente es soluble, o  $A^\top A$  está mal condicionada y  $x^\star = (A^\top A)^{-1} A^\top b$  explota.

- **Sobre-ajuste:** LS puro se ajusta al ruido de  $b$  y pierde poder de generalización.
- **Multicolinealidad:** con  $A^\top A$  singular o casi,  $A^\dagger$  amplifica errores.
- **Mal condicionamiento:**  $\kappa(A^\top A) = \kappa(A)^2 \gg 1$ .

## Idea central

Añadir al objetivo un **término de penalización**  $\lambda R(x)$  que “empuje” a  $x$  hacia un comportamiento deseado (pequeño, disperso, suave...).

# Regularización de Tikhonov ( $\ell_2$ )

$$\begin{aligned} \text{minimizar} \quad & \|Ax - b\|_2^2 + \lambda \|x\|_2^2 \\ & \lambda > 0 \text{ (parámetro de regularización)}. \end{aligned}$$

- $\lambda \rightarrow 0$ : recupera mínimos cuadrados.
- $\lambda \rightarrow \infty$ : domina el segundo término,  $x^* \rightarrow 0$ .
- **Condiciones de optimalidad:**  $(A^\top A + \lambda I)x = A^\top b$ .
- **Solución:**  $x^* = (A^\top A + \lambda I)^{-1} A^\top b$ .
- Resuelve el mal condicionamiento *siempre* ( $A^\top A + \lambda I \succ 0$ ).

## Nombres clásicos

Estadística: *ridge regression*. Visión por computador y reconstrucción de imágenes: *Tikhonov*.

## Otras penalizaciones frecuentes

| Nombre           | Objetivo                                          | Efecto              |
|------------------|---------------------------------------------------|---------------------|
| Ridge / Tikhonov | $\ Ax - b\ ^2 + \lambda \ x\ _2^2$                | x pequeño global    |
| Lasso            | $\ Ax - b\ ^2 + \lambda \ x\ _1$                  | x disperso (sparse) |
| Elastic net      | $\ Ax - b\ ^2 + \alpha \ x\ _2^2 + \beta \ x\ _1$ | disperso + estable  |
| Total variation  | $\ Ax - b\ ^2 + \lambda \text{TV}(x)$             | x suave a trozos    |

- **Selection de  $\lambda$ :** validación cruzada, cota sobre  $\|x\|$ , discrepancia (Morozov), curvas-L.
- **Forma en norma:** cualquier  $\phi(x)$  convexa, monótona en  $\|x\|$ , entrega un regularizador.

## Ajuste por función de penalización: $(P_\phi)$

En lugar de una norma, se puede usar una *función de penalización*:

$$\begin{array}{ll} \text{minimizar} & \phi(r_1) + \cdots + \phi(r_m) \\ \text{sujeto a} & r = Ax - b. \end{array} \quad (P_\phi)$$

con  $\phi : \mathbb{R} \rightarrow \mathbb{R}$  **convexa**. Tres elecciones clásicas:

$$\begin{array}{ll} \phi(u) = u^2 & \text{(cuadrática, sensible a outliers),} \\ \phi(u) = \max\{0, |u| - a\} & \text{(deadzone-lineal: ignora } |u| \leq a), \\ \phi(u) = \begin{cases} -(a^2/2) \log(1 - (u/a)^2) & |u| < a, \\ +\infty & |u| \geq a \end{cases} & \text{(log-barrera: fuerza } |u| < a). \end{array}$$

La forma de  $\phi$  controla la *distribución* del residuo.

## Supuesto

Los datos  $x_1, \dots, x_n \in \mathbb{R}$  son i.i.d. según una densidad

$$p(x; \theta), \quad \theta \in \Theta \subset \mathbb{R}^p.$$

La *familia paramétrica*  $\{p(\cdot; \theta)\}_{\theta \in \Theta}$  es conocida salvo el valor de  $\theta$ .

- *Ejemplos:* Gaussiana  $\mathcal{N}(\mu, \sigma^2)$ , exponencial  $\text{Exp}(\lambda)$ , Bernoulli, Poisson, mezcla finita.
- **Objetivo:** a partir de los datos, estimar  $\theta$ .



# Estimación por máxima verosimilitud (ML)

## Función de verosimilitud y log-verosimilitud

$$L(\theta) = \prod_{i=1}^n p(x_i; \theta), \quad \ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log p(x_i; \theta).$$

- El estimador de máxima verosimilitud (ML/MLE) es  $\theta_{\text{ML}} = \arg \max_{\theta} L(\theta) = \arg \min_{\theta} -\ell(\theta)$ .
- $-\ell$  es *suma de funciones* de la densidad  $p(\cdot; \theta)$  en cada dato: encaja como un problema de *penalización* ( $P_{\phi}$ ).

## Caso Gaussiano

Con  $p(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x-\mu)^2/(2\sigma^2)}$ ,  $\theta = (\mu, \sigma^2)$  y el negativo de la log-verosimilitud

$$-\ell(\mu, \sigma^2) = \frac{1}{2\sigma^2} \sum_i (x_i - \mu)^2 + \frac{n}{2} \log(2\pi\sigma^2),$$

cuya minimización da  $\hat{\mu} = \frac{1}{n} \sum_i x_i$  y  $\hat{\sigma}^2 = \frac{1}{n} \sum_i (x_i - \hat{\mu})^2$ .

# Estimación MAP = aproximación regularizada

## Estimador MAP (máximo a posteriori)

$$\theta_{\text{MAP}} = \arg \max_{\theta} \underbrace{p(\theta)}_{\text{priori}} \cdot \underbrace{p(x_1, \dots, x_n | \theta)}_{\text{verosimilitud}} = \arg \min_{\theta} [-\log p(x; \theta)] + [-\log p(\theta)].$$

- Es la **fusión de dos ingredientes convexos**: likelihood y priori.
- **Caso clave**: priori Gaussiano  $\theta \sim \mathcal{N}(0, \tau^2 I) \Rightarrow -\log p(\theta) = \frac{1}{2\tau^2} \|\theta\|_2^2 + \text{cte.}$  MAP = *Tikhonov* con  $\lambda = 1/\tau^2$ .

## Re-encuadre como problema convexo

ML:  $\min_{\theta} -\sum_i \log p(x_i; \theta)$ .

MAP:  $\min_{\theta} -\sum_i \log p(x_i; \theta) + \Omega(\theta)$  (penalización por la priori).

# Estimación no paramétrica: idea

- **No asumimos una forma paramétrica**  $p(x; \theta)$ .
- Objetivo: estimar la densidad  $p(x)$  en cada  $x$  (o una función desconocida  $f : \mathbb{R} \rightarrow \mathbb{R}$ ) *sólo* a partir de datos, sin conocimiento previo de su forma.
- Toda la información está en los datos: “*let the data speak*”.

## Resumen de los tres métodos que veremos

- 1 Estimación por *histogramas*.
- 2 Estimación por *kernel* (KDE).
- 3 Estimación por *k-vecinos más cercanos* ( $k$ -NN).

Dividir el rango en  $M$  celdas de ancho  $h$  y contar cuántos datos caen en cada una.

$$\hat{p}_{\text{hist}}(x) = \frac{1}{nh} \#\{i \mid x_i \text{ cae en la celda que contiene } x\}.$$

- **Ventaja:** extremadamente simple, rápida.
- **Desventaja:** discontinua en los bordes de celda, depende de  $M$  y de dónde se cortan las celdas.
- Elección del ancho  $h$ : sesgo vs. varianza (ancho pequeño  $\rightarrow$  alta varianza; ancho grande  $\rightarrow$  alto sesgo).

## Estimador de Parzen–Rosenblatt

$$\hat{p}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$

donde  $K : \mathbb{R} \rightarrow \mathbb{R}_+$  es un *kernel* (e.g. Gaussiano, Epanechnikov, triangular, uniforme) con  $\int K = 1$ .

- *Intuición*: poner una “campana”  $K$  sobre cada dato y promediar.
- Continuidad y suavidad heredadas de  $K$ .
- **Ancho de banda**  $h$ : controla el tradeoff sesgo/varianza — usualmente  $h \propto n^{-1/5}$  para datos en 1D.

# Estimación por $k$ -vecinos más cercanos

Idea: estimar la densidad en  $x$  por la *frecuencia local* alrededor de  $x$ , medida con la métrica de los  $k$  vecinos más próximos.

$$\hat{p}(x) = \frac{k/n}{\text{vol}(B(x, r(x)))}, \quad r(x) = \text{distancia al } k\text{-ésimo vecino más cercano de } x.$$

- *Análoga en clasificación*: asignar a  $x$  la clase mayoritaria de sus  $k$  vecinos más cercanos.
- **Ventaja**: no asume forma para la densidad; “adaptativa” (en regiones con pocos datos,  $r$  crece).
- **Costo**: requiere  $k$ -NN queries —  $O(n \log n)$  con árboles (KD-trees, ball-trees),  $O(nd)$  lineales.

## Proyección euclidiana de $x_0$ sobre $C$

$$\Pi_C(x_0) = \arg \min_{x \in C} \frac{1}{2} \|x - x_0\|_2^2.$$

- Si  $C$  es **convexo cerrado** no vacío, el problema tiene *única* solución (convexidad + función objetivo estrictamente convexa).
- Si  $C = \emptyset$ : no hay proyección. Si  $C$  no convexo: la proyección puede no ser única o no existir.

# Caracterización variacional de la proyección

$x^* = \Pi_C(x_0)$  si y sólo si se cumple la **condición variacional**:

$$(x_0 - x^*)^\top (x - x^*) \leq 0 \quad \forall x \in C.$$

- Lectura geométrica: el vector  $x^* - x_0$  es *normal* a  $C$  en el punto  $x^*$ , apuntando hacia adentro.
- Equivale a decir que  $x_0 - x^*$  pertenece al cono normal  $N_C(x^*)$ .

## Consecuencia clave

La condición variacional es el análogo convexo de las *condiciones KKT* para problemas con un único conjunto factible convexo.



# Ejemplos clásicos de proyección

- ❶ **Hiperplano**  $H = \{x \mid a^\top x = b\}$ :

$$\Pi_H(x_0) = x_0 + \frac{b - a^\top x_0}{\|a\|_2^2} a.$$

- ❷ **Half-space**  $H^- = \{x \mid a^\top x \leq b\}$ :  $\Pi_{H^-}(x_0)$  = proyección sobre  $H$  si  $a^\top x_0 \leq b$ ; en otro caso  $= x_0 + \frac{b - a^\top x_0}{\|a\|_2^2} a$ .

- ❸ **Bola euclidiana**  $B = \{c\} \oplus r\mathbb{B}$ :

$$\Pi_B(x_0) = \begin{cases} x_0 & \text{si } \|x_0 - c\|_2 \leq r, \\ c + r \frac{x_0 - c}{\|x_0 - c\|_2} & \text{si } \|x_0 - c\|_2 > r. \end{cases}$$

- ❹ **Caja**  $C = \{x \mid \mathbf{l} \preceq x \preceq \mathbf{u}\}$ :  $\Pi_C(x_0)$  se aplica coordenada a coordenada,  $[\Pi_C(x_0)]_i = \min(u_i, \max(\ell_i, x_{0,i}))$ .

# Proyección sobre conos y la PSD

- **Cono  $K$ :** la proyección sobre un cono convexo cerrado  $K$  satisface  $\Pi_K(x_0) = (x_0 - \Pi_{K^*}(x_0))$  (descomposición de Moreau).
- **Cono no negativo  $K = \mathbb{R}_+^n$ :**  $\Pi_{\mathbb{R}_+^n}(x_0)$  recorta a 0 las coordenadas negativas.
- **Cono PSD  $\mathcal{S}_+^n = \{S \mid S = S^\top, S \succeq 0\}$ :** la proyección euclidiana de  $x_0$  sobre  $\mathcal{S}_+^n$  es  $V \text{diag}(\lambda_+) V^\top$ , donde  $x_0 = V \text{diag}(\lambda) V^\top$  es la descomposición propia y  $\lambda_+ = \max(\lambda, 0)$ .
- **Cajas y poliedros:** en general la proyección sobre un poliedro se reduce a un  $QP$  (cuadrático convexo).

# Distancia entre dos conjuntos convexos

## Distancia euclidiana entre $C$ y $D$

$$\text{dist}(C, D) = \min_{x \in C, y \in D} \|x - y\|_2.$$

- Si  $C$  y  $D$  son *convexos compactos* no vacíos, la mínima distancia se alcanza y es positiva si y sólo si  $C \cap D = \emptyset$ .
- **Equivalencia de Weber:**  $\text{dist}(C, D) > 0$  si y sólo si existe un *hiperplano separador estricto* entre  $C$  y  $D$ .

La distancia se reformula como un **QP**:

$$\begin{array}{ll}\text{minimizar} & t \\ \text{sujeto a} & x \in C, y \in D, \|x - y\|_2 \leq t.\end{array}$$

- Útil cuando  $C, D$  están dados por conos o desigualdades: los conjuntos quedan como restricciones lineales/MI.
- Si  $C, D$  son **poliedros**: la distancia es un LP o un *second-order cone program* (SOCP).
- Si  $C, D$  son **elipsoides**: la distancia se reduce a un *problema de SDP*.

# Hiperplano separador y teoremas de separación

## Theorem (Separación estándar, B&V §2.5.1)

*Si  $C, D \subset \mathbb{R}^n$  son conjuntos convexos con intersección vacía, existen  $a \neq 0$  y  $b$  tales que*

$$a^\top x \leq b \quad \forall x \in C, \quad a^\top y \geq b \quad \forall y \in D.$$

## Theorem (Separación estricta, B&V §2.5.2)

*Si  $C, D$  son convexos cerrados no vacíos con intersección vacía y uno de ellos es compacto, existe  $a \neq 0$ ,  $b_1 < b_2$  con*

$$a^\top x \leq b_1 \quad \forall x \in C, \quad a^\top y \geq b_2 \quad \forall y \in D.$$

## Aplicaciones

Detección de factibilidad/infactibilidad, separación en clasificadores (SVM), verificación geométrica, condicionamiento.

- ➊ **Aproximación por norma** (B&V §6.1):  $\min \|Ax - b\|$ . Tres casos clásicos:  $\ell_2$  (cuadrática, pseudoinversa),  $\ell_\infty$  (LP, *minimax*),  $\ell_1$  (LP, robusto a outliers).
- ➋ **Mínima norma** (B&V §6.2):  $\min \|x\|$  s.a.  $Ax = b$ . Solución  $A^\dagger b$  en el  $\ell_2$ , freedom  $\ker A$  en general.
- ➌ **Aproximación regularizada** (B&V §6.4/§6.5): Tikhonov  $\min \|Ax - b\|^2 + \lambda \|x\|^2$ , solución  $(A^\top A + \lambda I)^{-1} A^\top b$ . Otras: Lasso, TV.
- ➍ **Aproximación paramétrica** (B&V §6.6): ML, MAP = ML + priori = regularización Tikhonov cuando  $\theta \sim \mathcal{N}(0, \tau^2 I)$ .
- ➎ **Aproximación no paramétrica** (B&V §6.6): histogramas, KDE ( $h \propto n^{-1/5}$ ),  $k$ -NN.
- ➏ **Proyección** (B&V §8.1):  $\Pi_C(x_0)$  única en  $C$  convexo cerrado; variacional  $\Leftrightarrow$  KKT. Recetas explícitas para hiperplanos, bolas, cajas, conos, PSD.
- ➐ **Distancia / separación** (B&V §8.2): QP si poliedros; existencia garantizada de hiperplano separador (estricto si uno es compacto).

-  S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. [stanford.edu/~boyd/cvxbook/](https://stanford.edu/~boyd/cvxbook/) (libro completo, PDF libre).
-  S. Boyd y L. Vandenberghe. *EE364A Slides*. Stanford, 2023.
-  A. N. Tikhonov y V. Ya. Arsenin. *Solutions of Ill-Posed Problems*. Winston, 1977.
-  R. Tibshirani. Regression shrinkage and selection via the lasso. *J. Royal Stat. Soc. B* 58(1):267–288, 1996.
-  T. Hastie, R. Tibshirani, J. Friedman. *The Elements of Statistical Learning*. Springer, 2nd ed., 2009.