

Funciones Convexas

Optimización Convexa — MM-520

May 26, 2026

Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es **convexa** si su dominio es un conjunto convexo y para todo x, y y todo $\theta \in [0, 1]$:

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y).$$

Una función es **estrictamente convexa** si la desigualdad es estricta ($<$) para $\theta \in (0, 1)$ cuando $x \neq y$.

Dominio efectivo:

$$\{x \in \mathbb{R}^n \mid f(x) < +\infty\}.$$

Epigrafo:

$$\{(x, t) \mid x \in \text{dom } f, f(x) \leq t\}.$$

f es convexa si y solo si su epigrafo es un conjunto convexo.

Desigualdad de Jensen

Si f es convexa, entonces para toda combinacion convexa $\theta_i \geq 0$, $\sum \theta_i = 1$:

$$f\left(\sum_{i=1}^m \theta_i x_i\right) \leq \sum_{i=1}^m \theta_i f(x_i).$$

En particular, con $\theta \in [0, 1]$: $f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$.

Condición de punto estacionario

Sea f convexa y diferenciable en $\text{dom } f$. Entonces: x^* es minimizador global si y solo si $\nabla f(x^*) = 0$.

Si f es estrictamente convexa, el minimizador (si existe) es único.

- **Función afín:** $f(x) = a^T x + b$ — Convexa y cóncava
- **Función cuadrática:** $f(x) = \frac{1}{2} x^T P x$, $P \succeq 0$ — Convexa
- **Norma euclidiana:** $f(x) = \|x\|_2$ — Convexa
- **Valor máximo:** $f(x) = \max\{x_1, \dots, x_n\}$ — Convexa
- **Log-sum-exp:** $f(x) = \log(e^{x_1} + \dots + e^{x_n})$ — Convexa
- **Entropía:** $f(x) = -\sum x_i \log x_i$, $\text{dom } f = \{x_i > 0\}$ — Cóncava

Condición de Primer Orden

Teorema (Condición de primer orden)


Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en un conjunto convexo abierto C . Entonces:
 f es convexa en C si y solo si:

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) \quad \forall x, y \in C.$$

Interpretación geométrica

La función siempre está por **encima** de su tangente en cualquier punto. El plano tangente en x es una **global underestimator** de f .

Visualización: Condición de Primer Orden



Condición de Segundo Orden

Teorema (Condición de segundo orden)

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ dos veces diferenciable en un conjunto abierto C . Entonces:
 f es convexa en C si y solo si:


$$\nabla^2 f(x) \succeq 0 \quad \forall x \in C,$$

es decir, la matriz Hessiana es **semidefinida positiva** en todo punto.

Caso unidimensional

Si $n = 1$: $f''(x) \geq 0$ para todo $x \iff f$ es convexa.

Visualización: Hessiana Positiva



Ejemplo: Función Cuadrática

Consideremos $f(x) = \frac{1}{2}x^T Px + q^T x + r$ con P simétrica.

Derivadas:

$$\nabla f(x) = Px + q, \quad \nabla^2 f(x) = P.$$

Por lo tanto:

- f es convexa $\iff P \succeq 0$ (semidefinida positiva).
- f es estrictamente convexa $\iff P \succ 0$ (definida positiva).

Resumen: Condiciones para Convexidad

Tipo	Condición	Para funciones
Zeroth-order	$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$	
Primer orden	$f(y) \geq f(x) + \nabla f(x)^T (y - x)$	
Segundo orden	$\nabla^2 f(x) \succeq 0$ (Hessiana semidefinida positiva)	

estrictamente convexas:

- $\nabla^2 f(x) \succ 0$ (Hessiana definida positiva)
- $f(y) > f(x) + \nabla f(x)^T (y - x)$ para $x \neq y$

Teorema de Composicion

Sea $f(x) = h(g(x))$ donde $g : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R} \rightarrow \mathbb{R}$:

h convexa, creciente + g convexa $\Rightarrow f$ convexa

h convexa, decreciente + g cóncava $\Rightarrow f$ convexa

h cóncava, creciente + g cóncava $\Rightarrow f$ cóncava

h cóncava, decreciente + g convexa $\Rightarrow f$ cóncava

Ejemplo: Si g es convexa, entonces $e^{g(x)}$ es convexa.

Suma ponderada: $\sum w_i f_i$ es convexa si $w_i \geq 0$ y cada f_i es convexa.

Maximo: $\max\{f_1, \dots, f_m\}$ es convexo.

Transformacion afin: $g(x) = f(Ax + b)$ es convexa si f lo es.

Minimizacion: $g(x) = \inf_{y \in C} f(x, y)$ es convexa si f lo es en x .

Definición: Transformada de Fenchel

Conjugada Convexa

Para $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$, su **conjugada convexa** f^* se define como:

$$f^*(y) := \sup_{x \in \text{dom } f} \{y^T x - f(x)\}.$$

Intuición: $f^*(y)$ mide la mayor “ganancia” $y^T x$ menos el “costo” $f(x)$.

Ejemplos de Conjugadas

Función lineal: $f(x) = a^T x + b$

$$f^*(y) = \begin{cases} -b & y = a \\ +\infty & y \neq a \end{cases}$$

Norma cuadrática: $f(x) = \frac{1}{2} \|x\|_2^2 \implies f^*(y) = \frac{1}{2} \|y\|_2^2$

Norma ℓ_1 : $f(x) = \|x\|_1$

$$f^*(y) = \begin{cases} 0 & \|y\|_\infty \leq 1 \\ +\infty & \|y\|_\infty > 1 \end{cases}$$

Exponencial: $f(x) = e^x$

$$f^*(y) = \begin{cases} y \ln y - y & y > 0 \\ 0 & y = 0 \\ +\infty & y < 0 \end{cases}$$

Fenchel-Moreau (Bidual)

Para toda función propia f semicontinua inferior: $f^{**} = f$.

Desigualdad de Young

Para todo $x, y \in \mathbb{R}^n$: $f(x) + f^*(y) \geq y^T x$,
con igualdad si y solo si $y \in \partial f(x)$ (subgradiente).

Cuasiconvexa

Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es **cuasiconvexa** si todos sus **conjuntos de nivel** son convexos:

$$S_\alpha = \{x \in \text{dom } f \mid f(x) \leq \alpha\} \quad \text{es convexo } \forall \alpha.$$

Equivalentemente: $f(\theta x + (1 - \theta)y) \leq \max\{f(x), f(y)\}$.

Convexa $\implies$ Cuasiconvexa.

Estrictamente convexa $\implies$ Estrictamente cuasiconvexa.

La recíproca **no** es cierta en general.

Contraejemplo: La función escalón $f(x) = \begin{cases} 1 & x \leq 0 \\ 0 & x > 0 \end{cases}$ es cuasiconvexa pero **no** convexa.

- El **máximo** de funciones cuasiconvexas es cuasiconvexo.
- La **minimización** preserva la cuasiconvexidad.

Log-concava

f es **log-concava** si $f > 0$ y $\log \circ f$ es cóncava:

$$f(\theta x + (1 - \theta)y) \geq f(x)^\theta f(y)^{1-\theta}.$$

Log-convexa

f es **log-convexa** si $f > 0$ y $\log \circ f$ es convexa:

$$f(\theta x + (1 - \theta)y) \leq f(x)^\theta f(y)^{1-\theta}.$$

Log-concava $\implies$ Cóncava. Y log-convexa $\implies$ Convexa.

Log-concavas

Función Gaussiana: $e^{-|x|^2/2}$, densidad normal multivariada, indicatrice de conjunto convexo.

Log-convexas

$f(x) = e^{x^2}$, función gamma $\Gamma(x)$ para $x > 0$.

La convolución de funciones log-concavas **preserva** la log-concavidad.

Cono propio

Un conjunto $K \subset \mathbb{R}^n$ es un **cono propio** si:

- 1 Es cerrado, solido y puntiagudo.
- 2 Es convexo.
- 3 Define orden: $x \succeq_K y \iff x - y \in K$.

Ejemplos:

$$K = \mathbb{R}_+^n: x \succeq_{\mathbb{R}_+^n} y \iff x_i \geq y_i \forall i$$

$$K = \mathcal{S}_+^n: X \succeq_{\mathcal{S}_+^n} Y \iff X - Y \text{ es semidefinida positiva}$$

K -convexa

Sea K un cono propio. $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es K -**convexa** si su dominio es convexo y para todo x, y y $\theta \in [0, 1]$:

$$f(\theta x + (1 - \theta)y) \preceq_K \theta f(x) + (1 - \theta)f(y).$$

Si $K = \mathbb{R}_+^m$, esto es el orden componente a componente.

Ejemplo: $f(X) = \lambda_{\max}(X)$ (máximo autovalor) es convexa con respecto a $\mathcal{S}_+^n$.

Cono dual: $K^* = \{y \mid y^T x \geq 0, \forall x \in K\}$. Para $K = \mathcal{S}_+^n$, $K^* = \mathcal{S}_+^n$.

Concepto	Definición
Función Convexa	$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$
Primer orden	$f(y) \geq f(x) + \nabla f(x)^T (y - x)$
Segundo orden	$\nabla^2 f(x) \succeq 0$
Conjugada	$f^*(y) = \sup\{y^T x - f(x)\}$
Cuasiconvexa	$\{f \leq \alpha\}$ es convexo $\forall \alpha$
Log-concava	$\log f$ es cóncava
K -convexa	$f(\theta x + (1 - \theta)y) \preceq_K \theta f(x) + (1 - \theta)f(y)$

-  Boyd, S. and Vandenberghe, L. *Convex Optimization*. Cambridge University Press, 2004.
-  Rockafellar, R.T. *Convex Analysis*. Princeton University Press, 1970.