

Optimización Convexa — Boyd & Vandenberghe

Capítulo 1: Introducción

minimizar $f_0(x)$

sujeto a $f_i(x) \leq b_i, \quad i = 1, \dots, m$

- $x = (x_1, \dots, x_n)$: variables de optimización
- $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$: función objetivo
- $f_i : \mathbb{R}^n \rightarrow \mathbb{R}, \quad i = 1, \dots, m$: funciones de restricción

La solución óptima x^* tiene el menor valor de f_0 entre todos los vectores que satisfacen las restricciones.

Ejemplo 1: Optimización de portafolio

¿De qué se trata?

Queremos decidir **cuánto dinero** invertir en diferentes activos financieros (acciones, bonos, etc.).

Elementos del problema

- **¿Qué decidimos?** Cuánto invertir en cada activo
- **¿Qué limitaciones tenemos?** No podemos gastar más de nuestro presupuesto; hay un mínimo y máximo por activo; queremos al menos cierto retorno
- **¿Qué queremos lograr?** Minimizar el riesgo total de la inversión (o maximizar el retorno esperado)

En esencia: decidir **cómo repartir el dinero** para ganar lo más posible sin arriesgar demasiado.

Ejemplo 2: Diseño de una viga

¿De qué se trata?

Queremos elegir las **dimensiones** de la sección transversal de una viga para que soporte un peso sin romperse, usando la menor cantidad de material posible.

Elementos del problema

- **¿Qué decidimos?** El ancho b y la altura h de la sección transversal de la viga
- **¿Qué limitaciones tenemos?** La viga no debe romperse (esfuerzo máximo permitido), no debe deformarse demasiado (deflexión máxima), y las dimensiones tienen límites prácticos
- **¿Qué queremos lograr?** Usar la **menor cantidad de material** posible (minimizar el área $b \times h$ o el costo)

En esencia: diseñar una viga que aguante la carga sin desperdiciar material.

Ejemplo 3: Ajuste de datos

¿De qué se trata?

Tenemos datos observados y queremos encontrar un **modelo matemático** que los explique bien.

Elementos del problema

- **¿Qué decidimos?** Los parámetros del modelo (pendientes, coeficientes, etc.)
- **¿Qué limitaciones tenemos?** Conocimiento previo del fenómeno, límites físicos de los parámetros
- **¿Qué queremos lograr?** Que el modelo **prediga** los datos con el menor error posible

En esencia: encontrar la curva o función que mejor se ajusta a una nube de puntos.

¿Por qué convexidad y optimización van juntos?

La intuición geométrica

Una función convexa tiene forma de como una **parábola** x^2 . Si suelta una canica en cualquier punto, **siempre** rueda hacia el fondo.

Problema convexo

- Un solo **mínimo global**
- Cualquier mínimo local **es** el global
- Algoritmos eficientes y confiables
- Solución garantizada

Problema no convexo

- Múltiples valles y picos
- Un mínimo local no es necesariamente el mejor
- Los algoritmos pueden **atascarse**
- Sin garantía de optimalidad

Moral: la convexidad es la propiedad que hace que optimizar sea **predecible, eficiente y seguro**.

Resolución de problemas de optimización

Problema de optimización general: muy difícil de resolver

Los métodos implican algún compromiso:

- Tiempo de computación muy largo, o
- No siempre se encuentra la solución

Excepciones: ciertas clases de problemas pueden resolverse de forma eficiente y confiable:

- Problemas de mínimos cuadrados
- Problemas de programación lineal
- Problemas de optimización convexa

$$\text{minimizar } \|Ax - b\|_2^2$$

Resolución:

- Solución analítica: $x^* = (A^\top A)^{-1} A^\top b$
- Algoritmos/software **confiable y eficiente**
- Tiempo de computación proporcional a n^2k ($A \in \mathbb{R}^{k \times n}$)

Uso:

- Fácil de reconocer
- Técnicas estándar aumentan la flexibilidad (pesos, regularización)

$$\text{minimizar } c^\top x \quad \text{sujeto a} \quad a_i^\top x \leq b_i, \quad i = 1, \dots, m$$

Resolución:

- No existe fórmula analítica
- Algoritmos **confiables y eficientes**
- Tiempo de computación proporcional a n^2m si $m \geq n$

Uso:

- **Más difícil de reconocer** que mínimos cuadrados
- Trucos estándar para convertir problemas (normas ℓ_1/ℓ_∞ , funciones lineales por partes)

Problema de optimización convexa

$$\text{minimizar } f_0(x) \quad \text{sujeto a} \quad f_i(x) \leq b_i$$

Las funciones objetivo y restricciones son **convexas**:

$$f_i(\alpha x + \beta y) \leq \alpha f_i(x) + \beta f_i(y) \quad \text{si } \alpha + \beta = 1, \alpha \geq 0, \beta \geq 0$$

Importante

Incluye mínimos cuadrados y programación lineal como **casos particulares**.

Resolución de problemas de optimización convexa

- No existe solución analítica
- Algoritmos **confiables y eficientes**
- Tiempo de computación aproximadamente proporcional a

$$\max\{n^3, n^2m, F\}$$

donde F = costo de evaluar f_i y sus derivadas

- **Casi una tecnología**

Uso:

- A menudo **difícil de reconocer**
- Muchos trucos para transformar a forma convexa
- Sorprendentemente **muchos problemas** son resolubles mediante optimización convexa

Ejemplo

m lámparas que iluminan n parches (pequeños y planos)

La iluminación I_k en el parche k depende linealmente de las potencias de las lámparas:

$$I_k = \sum_{j=1}^m a_{kj} p_j, \quad a_{kj} = r_{kj}^{-2} \max\{\cos \theta_{kj}, 0\}$$

Problema: lograr la iluminación deseada I_{des} con potencias de lámpara acotadas:

$$\text{minimizar } \max_{k=1, \dots, n} |\log I_k - \log I_{\text{des}}|$$

$$\text{sujeto a } 0 \leq p_j \leq p_{\max}, \quad j = 1, \dots, m$$

¿Cómo resolver?

1. **Potencia uniforme:** $p_j = p$, variar p
2. **Mínimos cuadrados:** minimizar $\sum (I_k - I_{\text{des}})^2$, redondear p_j si $p_j > p_{\text{max}}$ o $p_j < 0$
3. **Mínimos cuadrados ponderados:** minimizar $\sum (I_k - I_{\text{des}})^2 + \sum w_j (p_j - p_{\text{max}}/2)^2$, ajustar pesos iterativamente
4. **Programación lineal:** minimizar $\max |I_k - I_{\text{des}}|$ sujeto a $0 \leq p_j \leq p_{\text{max}}$
5. **Optimización convexa:** solución exacta con esfuerzo $\approx$ factor módico $\times$ esfuerzo de mínimos cuadrados

$$\text{minimizar } f_0(p) = \max_k h(l_k/l_{\text{des}}) \quad \text{donde } h(u) = \max\{u, 1/u\}$$

- f_0 es **convexa** porque el máximo de funciones convexas es convexo
- Solución exacta obtenida con esfuerzo $\approx$ factor módico $\times$ esfuerzo de mínimos cuadrados

Restricciones adicionales:

- (1) No más de la mitad de la potencia total en cualquier 10 lámparas $\rightarrow$ **todavía fácil**
- (2) No más de la mitad de las lámparas encendidas $\rightarrow$ **extrordinariamente difícil**

: La intuición no siempre funciona; problemas muy fáciles y muy difíciles pueden verse similares sin la formación adecuada.

Objetivos y temas del curso

Objetivos:

1. Reconocer/formular problemas como optimización convexa
2. Desarrollar código para problemas de tamaño moderado
3. Caracterizar soluciones óptimas

Temas:

1. Conjuntos, funciones y problemas de optimización convexos
2. Ejemplos y aplicaciones
3. Algoritmos

Optimización no lineal

Las técnicas tradicionales para problemas **no convexos** implican compromisos:

Optimización local (programación no lineal):

- Encuentra un punto que minimiza f_0 entre puntos factibles cercanos
- Rápida, maneja problemas grandes
- Requiere suposición inicial
- Sin información sobre la distancia al óptimo global

Optimización global:

- Encuentra la solución global
- La complejidad en el peor caso crece **exponencialmente** con el tamaño del problema
- A menudo basada en resolver subproblemas convexos

Breve historia de la optimización convexa

Teoría (Convex analysis)	Análisis convexo: ca. 1900–1970
Algoritmos	
1947	Simplex (Dantzig)
1960s	Métodos primitivos de punto interior (Fiacco & McCormick, Dikin)
1970s	Método del elipsoide
1980s	Punto interior polinomial para PL (Karmarkar 1984)
1980s–hoy	Punto interior polinomial para convexo no lineal (Nesterov & Nemirovski 1994)
Aplicaciones	
Antes de 1990	Mayormente investigación de operaciones
Desde 1990	Ingeniería (control, procesamiento de señales, comunicaciones, diseño de circuitos)
	Nuevas clases de problemas (SDP, SOCP, optimización ro-

¿Preguntas?

Optimización Convexa — Boyd & Vandenberghe
Capítulo 1: Introducción