14 de octubre de 2026

Esquema de la presentación

¿Por qué métodos iterativos?

Descenso de gradiente

Métodos con momento

SGD y ADAM

Método de Newton

Búsqueda lineal

Quasi-Newton y BFGS

Identidades de cálculo vectorial

Síntesis

El problema central

- Mínimo local de f suave y sin restricciones:

$$\nabla f(x^\star) = 0, \qquad \nabla^2 f(x^\star) \succeq 0.$$

- En general *no* se resuelve $\nabla f(x) = 0$ de forma explícita.
- Se busca una sucesión $x_{k+1} = F(x_k)$ tal que

$$f(x_0) \geq f(x_1) \geq \cdots \geq f(x_k) \to f(x^\star).$$

- Algoritmo ideal: rápido, monotono y de bajo coste por iteración.

Advertencia

El resultado solo es óptimo local, salvo que el problema sea convexo. En problemas no convexos la inicialización x_0 decide a qué mínimo se llega.

Dos familias

Métodos de primer orden

- Usan ∇f.
- Aproximación lineal de f.
- Escala a sistemas muy grandes.
- Base del aprendizaje automático.
- Ej.: gradiente, momento, *SGD*, ADAM.

Métodos de segundo orden

- Usan $\nabla^2 f$ (Hessian).
- Aproximación cuadrática de f.
- Menos iteraciones.
- Mayor coste y memoria.
- Ej.: Newton, *quasi*-Newton, BFGS.

Ventaja común: se asume muy poca estructura, solo la existencia de derivadas.

El algoritmo

$$\boxed{x_{k+1} = x_k - \gamma \nabla f(x_k)}$$

- $-\nabla f(x_k)$ es la dirección de máximo descenso local.
- $\gamma > 0$ es el tamaño de paso o *learning rate*.
- Se apoya en la aproximación de Taylor de primer orden:

$$f(x_k + \Delta x) \approx f(x_k) + \nabla f(x_k)^T \Delta x.$$

- Cerca del mínimo el gradiente se hace pequeño y los pasos se acortan solos.
- En objetivos no convexos, cada punto cae en el mínimo local más cercano.

Brunton, *Optimization Bootcamp*, Cap. 2

¿Cómo elegir el paso γ?

Criterio	Descripción
Fijo	Simple; funciona bien si el Hessian está bien condicionado.
Decreciente	$\gamma_k = \gamma_0/(1+\beta k)$; pasos grandes al inicio.
Búsqueda lineal	Optimiza γ en cada iteración (Sección 2.5).
Momentum	Aporta inercia para cruzar regiones planas (Sección 2.2).
Adaptativo	RMSProp y ADAM ajustan el paso con el historial.
Programas	Decaimiento exponencial u otros horarios por etapas.

Panel 2.1. Búsqueda lineal: $\gamma_k = \arg\min_{\gamma>0} f(x_k - \gamma \nabla f(x_k))$; en la práctica se recorre γ de forma iterativa.

Ejemplo cuadrático

$$f(x) = \tfrac{1}{2} x^T A x, \qquad A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \succ 0, \qquad x^\star = 0.$$

- Problema de referencia: la solución se conoce de antemano.
- $\gamma = 0{,}01$: convergencia lenta.
- $\gamma = 0{,}1$: convergencia rápida y sin oscilaciones.
- $\gamma = 0{,}543$: casi inestable, oscila alrededor del mínimo.

Espacio reservado para figura

Trayectorias sobre curvas de nivel y curva $f(x_k)$ para los tres pasos.

Brunton, Figura 2.3

Convergencia de gradiente

Caso 1. f convexa y ∇f Lipschitz con constante L, con $\gamma = 1/L$:

$$f(x_k) - f(x^\star) \leq \frac{L}{2k} \|x_0 - x^\star\|^2 \qquad \Longrightarrow \qquad \mathcal{O}(1/k).$$

Caso 2. f μ-fuerte convexa:

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) + \tfrac{\mu}{2} \|y - x\|^2,$$

$$f(x_k) - f(x^\star) \leq \frac{L}{2} \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^\star\|^2.$$

- Para $f(x) = \frac{1}{2} x^T A x$ se cumple $\mu = \lambda_{\text{mín}}(A)$.
- La fuerte convexidad se reutiliza en la envoltura de Moreau (Sección 5.1).

Flujo de gradiente

Considérese la ecuación diferencial

$$\dot{x}(t) = -\nabla f\big(x(t)\big).$$

El campo $-\nabla f$ es un *gradient flow*: conservativo, irrotacional e incompresible si $\nabla^2 f = 0$. El paso de Euler hacia adelante es

$$x_{k+1} = x_k + \Delta t\, v(x_k),$$

y al tomar $\Delta t = \gamma$ se recupera exactamente el descenso de gradiente.

Consecuencia

Un esquema numérico mejor para el mismo flujo, como Runge–Kutta de orden superior, produce un algoritmo de descenso distinto (ejercicios 2.7 y 2.8).

Panel 2.2

Estabilidad en el caso cuadrático

$$f(x) = \tfrac{1}{2} x^T A x + b^T x + c, \qquad \nabla f(x) = Ax + b.$$
$$x_{k+1} = x_k - \gamma(Ax_k + b) = (I - \gamma A)x_k - \gamma b.$$

- El factor iterativo es $I - \gamma A$, con autovalores $1 - \gamma\lambda_j$.
- A simétrica: $\nabla^2 f = A$. Si A no lo es, $\nabla f = \frac{1}{2}(A + A^T)x + b$ y $\nabla^2 f = \frac{1}{2}(A + A^T)$.
- Estabilidad: $|1 - \gamma\lambda_j| < 1$ para todo j.
- De ahí

$$\boxed{0 < \gamma < \gamma_{\text{máx}} = \frac{2}{\lambda_{\text{máx}}}}.$$

Paso óptimo

La tasa la fija el radio espectral $\rho(I - \gamma A) = \max_j |1 - \gamma\lambda_j|$. Los autovalores son simétricos respecto de $1 - \gamma\lambda_{\mathrm{mid}}$, con $\lambda_{\mathrm{mid}} = (\lambda_{\min} + \lambda_{\max})/2$. El mínimo se alcanza al distribuirlos simétricamente respecto del origen:

$$1 - \gamma^\star \lambda_{\min} = -(1 - \gamma^\star \lambda_{\max}),$$

$$\boxed{\gamma^\star = \frac{2}{\lambda_{\min} + \lambda_{\max}}}, \qquad \boxed{\rho = \frac{\lambda_{\max} - \lambda_{\min}}{\lambda_{\min} + \lambda_{\max}}}.$$

- ρ es la contracción peor caso por iteración.
- Gran dispersión de autovalores $\Rightarrow$ convergencia lenta.

¿Por qué iterar si $Ax = b$?

Aunque $x^\star = -A^{-1}b$ se pueda calcular, el descenso de gradiente conviene cuando la inversa es intratable:

- A **grande:** con n en millones o miles de millones, A^{-1} ni siquiera cabe en memoria; el producto Ax sí puede estar disponible.
- A **dispersa:** común en física (mecánica de fluidos: difusión y convección son interacciones locales); los métodos iterativos ganan.
- A **mal condicionada:** la inversión directa es inexacta; se usan precondicionadores y descenso iterativo.

Brunton, *Optimization Bootcamp*, Cap. 2

El problema

- Cerca de un punto de silla, $\|\nabla f\|$ es diminuto: el descenso se estanca.
- Con *SGD* el problema se agrava: la estimación del gradiente además es ruidosa.
- El momento *integra* gradientes pasados: suaviza el ruido y aporta inercia.
- Analogía física: una bola que acelera en pendiente conserva velocidad y atraviesa regiones planas.

Idea

Reemplazar el gradiente instantáneo por una media móvil exponencial de gradientes previos.

Heavy ball

$$\boxed{x_{k+1} = x_k - \gamma \nabla f(x_k) + \beta\,(x_k - x_{k-1})}$$

o, introduciendo la velocidad $v_k = x_k - x_{k-1}$:

$$v_{k+1} = \beta v_k - \gamma \nabla f(x_k), \qquad x_{k+1} = x_k + v_{k+1}.$$

- Nuevo hiperparámetro $\beta \in [0, 1)$: tasa de decaimiento de la velocidad.
- v_k es una suma descontada exponencialmente de gradientes previos.
- $\beta = 0$ recupera el descenso de gradiente simple.

Brunton, *Optimization Bootcamp*, Cap. 2

Heavy ball como sistema mecánico

La iteración surge de la EDO de segundo orden con fricción

$$m\ddot{x}(t) = -\nabla f\big(x(t)\big) - \delta\,\dot{x}(t).$$

Con diferencias centradas para $\ddot{x}$ y Euler para $\dot{x}$, paso Δt:

$$\gamma = \frac{\Delta t^2}{m + \delta\,\Delta t}, \qquad \beta = \frac{m}{m + \delta\,\Delta t}.$$

- m es la masa (inercia) y δ el coeficiente de fricción.
- Si $\delta = 0$: $\beta = 1$, sin pérdida de momento.
- Relación explícita entre los hiperparámetros y la dinámica física.

Panel 2.3

Nesterov: mirar antes de bajar

$$\boxed{\begin{aligned} y_k &= x_k + \beta v_k \qquad \text{(punto anticipado)} \\ x_{k+1} &= y_k - \gamma \nabla f(y_k) \end{aligned}}$$

- Único cambio respecto a heavy ball: el gradiente se evalúa en y_k, no en x_k.
- Equivale a un esquema tipo Runge–Kutta.
- Sutskever: NAG invierte el orden de momentum y descenso.
- Ventaja: la dirección ya incorpora la inercia, así no se pierde velocidad al llegar a una región plana.

Convergencia de Nesterov

f convexa, ∇f Lipschitz con constante L:

$$f(x_k) - f(x^\star) \leq \frac{2L}{(k+1)^2} \|x_0 - x^\star\|^2 \qquad \Longrightarrow \qquad \mathcal{O}(1/k^2).$$

f μ-fuerte convexa:

$$f(x_k) - f(x^\star) \leq 2\left(1 - \sqrt{\tfrac{\mu}{L}}\right)^k \left[f(x_0) - f(x^\star)\right].$$

- De $\mathcal{O}(1/k)$ a $\mathcal{O}(1/k^2)$: gran mejora.
- Caso fuerte convexo: decaimiento geométrico, es decir lineal.

Nesterov como EDO

$$\ddot{x}(t) + \frac{3}{t}\dot{x}(t) + \nabla f\big(x(t)\big) = 0, \qquad x(0) = x_0, \quad \dot{x}(0) = 0.$$

- El límite continuo de NAG es esta EDO de segundo orden.
- El tiempo se relaciona con el paso por $t \approx \sqrt{k\gamma}$, con $\gamma \leq 1/L$.
- El término $3/t$ es el que aporta la ganancia de orden dos.

AdaGrad y RMSProp

AdaGrad: acumula los cuadrados del gradiente, coordenada a coordenada:

$$r_k = r_{k-1} + g_k^{\odot 2}, \qquad x_{k+1} = x_k - \gamma \, \frac{g_k}{\sqrt{r_{k+1}} + \epsilon}.$$

- Cada coordenada recibe un paso propio según su historial.
- Problema: r_k sólo crece, así que el paso se apaga con el tiempo.

RMSProp: introduce un factor de decaimiento:

$$\boxed{r_{k+1} = \beta_2 r_k + (1 - \beta_2)\, g_k^{\odot 2}}$$

- Media móvil exponencial de cuadrados: paso acotado y estable.
- Particularmente eficaz con problemas mal condicionados.

Mínimos cuadrados como ajuste

Dados N pares (x_j, y_j), se buscan los parámetros θ que ajustan la función f_θ:

$$\min_{\theta} \sum_{j=1}^{N} \left\| f_\theta(x_j) - y_j \right\|^2.$$

La función de pérdida es $L(x, y; \theta) = \|f_\theta(x) - y\|^2$, con gradiente

$$\nabla L = 2\, \nabla f_\theta^T \, (f_\theta(x) - y).$$

- Es un problema de mínimos cuadrados no lineal.
- ∇f_θ se calcula analíticamente o por retropropagación.
- La retropropagación es la regla de la cadena aplicada capa a capa.
- Detalles en el Capítulo 10.

Descenso estocástico

En vez del gradiente sobre todo el conjunto, se usa un subconjunto aleatorio (un *lote*):

$$\hat{\nabla} L_k = \frac{1}{|B_k|} \sum_{j \in B_k} \nabla L(x_j, y_j; \theta), \qquad \boxed{\theta_{k+1} = \theta_k - \gamma \, \hat{\nabla} L_k}.$$

- La iteración es idéntica a la del gradiente clásico: la diferencia está escondida en el estimador del gradiente.
- Ventajas: velocidad, robustez al ruido, mejor exploración del paisaje y mejor generalización.
- Salida fácil: es la base de todas las variantes de momentum y de aprendizaje adaptativo.
- Nuevo hiperparámetro: el tamaño del lote.

Brunton, *Optimization Bootcamp*, Cap. 2

Tamaño del lote

El gradiente completo y el SGD puro (lote de 1) son los extremos del mini-lote.

- Lote grande: menos ruido, pero más caro por paso.
- Lote pequeño: pasos más baratos y más rápidos, pero más ruido; con ruido fuerte conviene un lote mayor para amortiguarlo.
- En un ejemplo lineal, un lote de 10 equilibra convergencia y tiempo.
- Comparación típica: gradiente completo, mini-lote (50) y lote de 1. Los dos últimos convergen en muchas menos épocas.

Precaución

Una época de SGD con lote 1 son N pasos individuales, no uno.

Espacio reservado para figura

Convergencia (MSE) de gradiente completo, mini-lote y SGD, y tiempo de cómputo según tamaño de lote.

Brunton, Figuras 2.7–2.9

ADAM

Combina momentum (primer momento) con la escala adaptativa de RMSProp (segundo momento). Sea $g_k = \nabla f(x_k)$:

$$m_k = \beta_1 m_{k-1} + (1-\beta_1)\, g_k, \qquad v_k = \beta_2 v_{k-1} + (1-\beta_2)\, g_k^{\odot 2},$$

$$\hat{m}_k = \frac{m_k}{1-\beta_1^k}, \qquad \hat{v}_k = \frac{v_k}{1-\beta_2^k},$$

$$\boxed{x_{k+1} = x_k - \gamma\, \frac{\hat{m}_k}{\sqrt{\hat{v}_k} + \epsilon}}.$$

- Las correcciones $1-\beta^k$ unbiased estiman los momentos al principio, cuando están sesgados.
- El gradiente estocástico está implícito dentro de $\hat{\nabla} L$.
- Estándar de facto para entrenar redes neuronales: Su artículo original fue el más citado del mundo, en cualquier campo, durante una década completa.

Aproximación cuadrática

En vez de la expansión lineal, se usa la de segundo orden:

$$f(x) \approx f(x_k) + \nabla f(x_k)^T \Delta x + \tfrac{1}{2} \Delta x^T H_k \, \Delta x, \qquad H_k = \nabla^2 f(x_k).$$

Derivando e igualando a cero,

$$\nabla f(x_k) + H_k \Delta x = 0 \qquad \Longrightarrow \qquad \boxed{x_{k+1} = x_k - H_k^{-1} \nabla f(x_k)}.$$

- El Hessian es simétrico (propiedad conmutativa de las derivadas mixtas).
- En una dimensión: $x_{k+1} = x_k - f'(x_k)/f''(x_k)$.
- Equivale al descenso de gradiente con paso $\gamma = 1/H_k$.

Newton: convergencia y escalado

Si $f \in C^2$, $\nabla^2 f$ es Lipschitz y $\nabla^2 f(x^\star)$ es definido positivo:

$$\|\epsilon_{k+1}\| \leq C \|\epsilon_k\|^2.$$

- **Convergencia cuadrática:** los dígitos correctos casi se duplican en cada paso. Mucho más rápido que $\mathcal{O}(1/k^2)$.
- **Memoria** $O(n^2)$ y coste $O(n^3)$ para la inversa de H.
- Problema 1: el Hessian puede ser inaccesible o demasiado caro.
- Problema 2: puede no ser definido positivo (máximo local o silla).

De ahí nacen los métodos *quasi*-Newton.

Newton en la práctica

- Nunca se invierte H explícitamente: se resuelve $H_k p_k = -\nabla f(x_k)$.
- Lejos de x_k el modelo cuadrático pierde calidad: se usa sólo para obtener la *dirección* $p_k = H_k^{-1}\nabla f(x_k)$ y luego se hace una búsqueda lineal en esa dirección.
- Si H_k no es definido positivo se amortigua:

$$(H_k + \alpha I)p_k = -\nabla f(x_k), \qquad \alpha \geq 0,$$

  y luego se busca el paso en la dirección p_k.
- Levenberg–Marquardt es el método clásico de Gauss–Newton amortiguado (Sección 4.7).

Espacio reservado para figura

Trayectoria de Newton sobre un paisaje no convexo, encajando un modelo cuadrático local.

Brunton, Figura 2.12

Dirección y paso

Con una dirección de descenso p_k y una iteración $x_{k+1} = x_k + \alpha_k p_k$:

- El *algoritmo* elige la dirección p_k: gradiente, momentum o Newton.
- La *búsqueda lineal* elige $\alpha_k > 0$ de forma adaptativa.
- Búsqueda exacta: $\alpha_k = \arg\min_{\alpha>0} f(x_k + \alpha p_k)$. Casi nunca se usa, salvo en problemas cuadráticos.
- En la práctica se hace una búsqueda *inexacta*: barrer α.

Por qué importa

Añade algunas evaluaciones de f por iteración, pero reduce el número de iteraciones *un orden de magnitud* y aporta gran robustez. En métodos de segundo orden el sobrecoste es despreciable frente a calcular el Hessian, así que se usa siempre.

Las tres familias

Criterio	Descripción
Armijo	Disminución suficiente; robusto y fácil de implementar, aunque a veces demasiado conservador.
Wolfe	Armijo más una condición de curvatura, que impide pasos demasiado pequeños. Es el usado en BFGS y L-BFGS.
BB (Barzilai–Borwein)	Usa los dos últimos iterados para aproximar un paso *quasi*-Newton; muy eficaz con problemas mal condicionados.

Regla práctica

Para gradiente completo: siempre Armijo, vuelve competitivo al gradiente con los métodos *quasi*-Newton. Para Newton: esencial para la convergencia global. Con SGD la búsqueda lineal es difícil y poco habitual.

Armijo por retroceso

Con $d^T O \nabla f(x) < 0$ (dirección de descenso), se busca $\alpha > 0$ tal que

$$\boxed{f(x + \alpha d) \leq f(x) + c_1\, \alpha\, d^T \nabla f(x)}, \qquad c_1 \in (0, 1).$$

1. Inicializar $\alpha \leftarrow \alpha_0$ (a menudo $\alpha_0 = 1$, o el tamaño del paso de Newton).
2. Mientras no se cumpla: $\alpha \leftarrow \rho\, \alpha$ con $\rho \in (0, 1)$ (p. ej. $\rho = \frac{1}{2}$), y volver a evaluar $f(x + \alpha d)$.
3. Aceptar el primer α válido y actualizar $x \leftarrow x + \alpha d$.

- Valores habituales: $c_1 \in [10^{-4}, 10^{-2}]$ y $\rho \in [0{,}1, 0{,}8]$.

Condiciones de Wolfe

Además de la disminución suficiente, se exige una condición de curvatura:

$$|d^T \nabla f(x + \alpha d)| \leq c_2 \, |d^T \nabla f(x)|, \qquad 0 < c_1 < c_2 < 1.$$

1. **Expansión:** se dan pasos de tamaño Δx y $2\Delta x$ (con Δx el tamaño del paso de Newton) hasta encontrar un punto válido, es decir donde $f_2 > f_1$ o $\nabla f_2 > 0$. Ambos casos indican que hay un mínimo entre los dos puntos.
2. **Zoom:** dentro de esa región se reduce el intervalo por bisección hasta encontrar el punto. Con varios puntos disponibles se puede usar interpolación por splines.

La condición de curvatura impide que el paso sea arbitrariamente pequeño.

Coste de la búsqueda lineal

El coste relativo de ∇f frente a f depende del problema:

- **Diferencias finitas:** $\sim n$ evaluaciones de f.
- **Regresión:** f y ∇f cuestan del mismo orden (una pasada sobre los datos), con un factor constante de 2 a 3.
- **Diferenciación automática:** el gradiente escala igual que el objetivo, con un coste constante mayor.
- **Problemas con PDE:** f requiere una solución directa del PDE hacia adelante; ∇f requiere además la solución adjunta. El coste marginal del gradiente es aproximadamente una solución extra.

Brunton, *Optimization Bootcamp*, Cap. 2

Aproximar el Hessian

Se reemplaza H por una matriz A que da una aproximación cuadrática

$$\tilde{f}_A(y) = f(x) + \nabla f(x)^T(y - x) + \tfrac{1}{2}(y - x)^T A(y - x).$$

Condiciones sobre A:

- Simétrica, porque H lo es.
- Definida positiva: se va a invertir, y cualquier $A \succ 0$ da dirección de descenso.
- Consistente en gradiente: $\nabla \tilde{f}_A(x_k) = \nabla f(x_k)$ y $\nabla \tilde{f}_A(x_{k-1}) = \nabla f(x_{k-1})$.
- Lo más cerca posible de A_{k-1} (proximidad en alguna norma).

Inicialización

Lo habitual es $A_0 = B_0 = I$, con $B = A^{-1}$ la inversa aproximada.

Ecuaciones de secante

Se definen

$$p_k = x_{k+1} - x_k, \qquad q_k = \nabla f(x_{k+1}) - \nabla f(x_k).$$

Como $H\Delta x \approx \Delta g$, la aproximación debe satisfacer

$$\boxed{A_k p_k = q_k}, \qquad \boxed{B_k q_k = p_k}.$$

- Sólo se necesita un par (p_k, q_k) por iteración.
- $p_k^T q_k > 0$ garantiza que la curvatura es positiva.
- Es una *ecuación secante*: no hace falta el Hessian completo.

Panorama de métodos

Método	Rango	Idea
SR1	1	Actualización de rango 1; simple, usada en métodos de región de confianza.
PSB	2	Minimiza la distancia de Frobenius $\|A_k - A_{k-1}\|_F$ con A_k simétrica; no garantiza que A_k sea definida positiva.
DFP	2	Distancia de Frobenius ponderada con una matriz W especial; garantiza que A_k siga siendo definida positiva.
BFGS	2	El más estable y el más usado; actualiza directamente B_k.

Panel 2.4. Familia de Broyden: $B_{k+1} = (1-\alpha)B_{k+1}^{\mathrm{BFGS}} + \alpha B_{k+1}^{\mathrm{DFP}}$, con $\alpha \in [0,1]$; en la práctica se toma $\alpha = 0$, es decir BFGS. **L-BFGS** restringe el historial a los últimos pares.

BFGS

Con $\rho_k = 1/(q_k^T p_k)$ y denotando $\rho_k q_k^T p_k > 0$, la actualización de B_k es

$$\boxed{B_{k+1} = \left(I - \rho_k p_k q_k^T\right) B_k \left(I - \rho_k q_k p_k^T\right) + \rho_k p_k p_k^T}.$$

- Actualización de rango 2: cada término posterior a B_k es de rango 1.
- Garantiza simetría y que B_{k+1} siga siendo definida positiva.
- Se usa B_k directamente en el paso $p_k = -B_k \nabla f(x_k)$: no hace falta invertir nada.
- Costo por iteración: sólo productos matriz–vector.

Sherman–Morrison y Woodbury

Ambas fórmulas permiten invertir actualizaciones de rango bajo sin operar con la matriz completa:
Sherman–Morrison (rango 1):

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^TA^{-1}}{1 + v^TA^{-1}u}.$$

Woodbury (rango k, con $U, V \in \mathbb{R}^{n\times k}$):

$$(A + UV^T)^{-1} = A^{-1} - A^{-1}U\left(I + V^TA^{-1}U\right)^{-1}V^TA^{-1}.$$

- Ambas sólo requieren productos matriz–vector y productos internos.
- Son la base computacional de BFGS y de las demás actualizaciones.

Identidades esenciales

Se usan una y otra vez al calcular gradientes:

1. Producto escalar con vector constante:

$$\nabla(c^T x) = \nabla(x^T c) = c.$$

2. Producto matriz–vector y su transpuesto:

$$D(Ax) = A, \qquad \nabla(x^T A) = A.$$

3. Forma cuadrática:

$$\nabla(x^T Ax) = (A + A^T)x, \qquad = 2Ax \quad \text{si } A \text{ es simétrica.}$$

Consecuencia

Para $f(x) = \frac{1}{2}x^T Ax + b^T x + c$ sin simetría: $\nabla f = \frac{1}{2}(A + A^T)x + b$ y $\nabla^2 f = \frac{1}{2}(A + A^T)$. El Hessian es simétrico aunque A no lo sea.

Identidades de la cadena

Para $f : \mathbb{R}^m \to \mathbb{R}$ y matriz $A \in \mathbb{R}^{n \times m}$:

$$\boxed{\nabla\big(f(Ax)\big) = A^T \nabla f(Ax)}$$

y, aplicada a derivadas de segundo orden,

$$\boxed{\nabla^2\big(f(Ax)\big) = A^T\big(\nabla^2 f(Ax)\big)A}.$$

- Son la base de la retropropagación y de los métodos adjuntos.
- $D(Ax)$ es el Jacobiano de Ax; a veces se denota $\nabla(Ax)$.
- Todas las identidades se obtienen expandingiendo el producto término a término y derivando.

Panel 2.5. $\nabla c^T x = c; \quad D(Ax) = \nabla(x^T A) = A; \quad \nabla(x^T Ax) = (A + A^T)x.$

Comparación de los métodos

Método	Orden	Tasa (convexa)	Cuándo usarlo
Gradiente	1	$\mathcal{O}(1/k)$	Simplicidad y escala; problemas bien condicionados.
Nesterov	1	$\mathcal{O}(1/k^2)$	Se mantienen pasos grandes; regiones planas.
SGD/ADAM	1	ruidosa	Datos masivos; estándar en aprendizaje automático.
Newton	2	cuadrática	Pocas iteraciones; H disponible.
BFGS/L-BFGS	2	cuadrática (superalineal)	H caro o no definido positivo.

Idea fuerza

Sólo los métodos de primer orden escalan a millones de parámetros. Los de segundo orden ganan en número de iteraciones, pero exigen Hessian y pueden fallar si no es definido positivo.

Puntos para recordar

1. Elegir el paso es tan importante como elegir la dirección; la búsqueda lineal es la herramienta más fiable.
2. El momento aporta inercia y convierte $\mathcal{O}(1/k)$ en $\mathcal{O}(1/k^2)$.
3. El mini-lote reduce el coste por paso a cambio de ruido: es el precio de la escalabilidad.
4. Newton converge cuadráticamente, pero necesita el Hessian y puede necesitar amortiguamiento y búsqueda lineal.
5. BFGS reutiliza la curvatura por pares secantes, sin construir H.

Idea final

La elección del método depende del balance entre coste por iteración, número de iteraciones, calidad del Hessian y estructuración del problema.

Para profundizar

Textos

- Marsden y Tromba, *Vector Calculus*, 2003.

Artículos

- Kingma y Ba, *Adam: A Method for Stochastic Optimization*, 2014.
- Rumelhart, Hinton y Williams, *Learning Representations by Back-propagating Errors*, *Nature*, 1986.
- Polyak, *Some Methods of Speeding Up the Convergence of Iteration Methods*, 1964.
- Nesterov, *A Method for Unconstrained Convex Minimization Problem with the Rate of Convergence* $\mathcal{O}(1/k^2)$, 1983.
- Dennis y Moré, *Quasi-Newton Methods, Motivation and Theory*, *SIAM Review*, 1977.
- Liu y Nocedal, *On the Limited Memory BFGS Method for Large Scale Optimization*, 1989.

¿Preguntas?