

Introducción a la Optimización Numérica

Conceptos fundamentales: anatomía, convexidad,
gradientes, restricciones y aplicaciones

Maestría en Matemática — UNAH
Universidad Nacional Autónoma de Honduras

22 de septiembre de 2026

Esquema de la presentación

Anatomía de un problema de optimización

Convexidad en optimización

Gradientes y la geometría de la optimización

Restricciones y multiplicadores de Lagrange

Aplicaciones de la optimización

Forma estándar de un problema de optimización

Problema sin restricciones

En su forma más simple, optimizamos una *función objetivo* $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sobre una *variable de decisión* $x \in \mathbb{R}^n$:

$$\min_{x \in \mathbb{R}^n} f(x).$$

En una variable basta con buscar x donde $f'(x) = 0$ y $f''(x) > 0$.

Forma estándar con restricciones (Ec. (1.2)–(1.3))

$$\begin{aligned} &\min_x f(x) \\ &\text{s.a. } g_i(x) \leq 0, \quad i = 1, \dots, m, \\ &\quad h_j(x) = 0, \quad j = 1, \dots, p. \end{aligned}$$

Las restricciones definen el *conjunto factible* $\mathcal{S} = \{x : g(x) \leq 0, h(x) = 0\}$.

- ▶ Maximizar una f cóncava equivale a minimizar $-f$ (convexa).
- ▶ En un programa lineal $f(x) = c^\top x$ es convexa y cóncava.

Anatomía visual y ejemplo introductorio

Ejemplo (Panel 1.1: proyectil)


El alcance de un proyectil lanzado con rapidez v a ángulo α es

$$D(\alpha) = \frac{v^2}{g} \sin(2\alpha).$$

Derivando: $D'(\alpha) = 0$ en el óptimo $\Rightarrow \alpha^* = \pi/4$. *El óptimo sin restricción está en el borde del dominio factible.*

Ingredientes del problema:

- ▶ Función objetivo $f(x)$.
- ▶ Variable de decisión $x \in \mathbb{R}^n$.
- ▶ Restricciones de igualdad h y desigualdad g .
- ▶ Conjunto factible $\mathcal{S} = \{x : g \leq 0, h = 0\}$.



Problemas comunes: LP y QP

Ejemplos clave en la práctica

Programación lineal (LP)

$$\max_x c^T x$$

$$\text{s.a. } Ax \leq b, \quad x \geq 0.$$

Objetivo y restricciones son lineales; el conjunto factible S es un *politopo*. El *óptimo* está en un *vértice del politopo*.

Programación cuadrática (QP)


$$\min_x \frac{1}{2} x^T Q x + c^T x$$

$$\text{s.a. } Ax \leq b, \quad x \geq 0.$$

Convexa si $Q \succeq 0$ (semidefinida positiva).

Ejemplo central: *mínimos cuadrados*

$$\min_x \frac{1}{2} \|Ax - b\|_2^2, \text{ con } Q = A^T A.$$



Preguntas frecuentes sobre la función objetivo

Antes de elegir un algoritmo, conviene hacerse estas preguntas sobre f :

¿ f es convexa?

Si f y $\mathcal{S}$ son convexos, *todo óptimo local es global*. Mínimos cuadrados lineales es convexo; entrenar una red neuronal, no.

¿Podemos calcular ∇f ?

Si sí: descenso por gradiente o Newton (Cap. 2). Si no: métodos sin gradiente (Cap. 5) o adjunto / surrogate.

¿ f es lineal, cuadrática, general?

Lineal $\Rightarrow$ LP. Cuadrática con Hessiana $H \succ 0 \Rightarrow$ convexa; H indefinida $\Rightarrow$ punto silla; H negativa $\Rightarrow$ cóncava.

Otras preguntas

¿Alta dimensión? ¿ f desconocida / caja negra? ¿Cara de evaluar? ¿Codifica dinámica temporal? Cada pregunta cambia el método apropiado.

Conjuntos convexos

Definición (Conjunto convexo)

Un conjunto $C \subseteq \mathbb{R}^n$ es *convexo* si para todo par $x, y \in C$ y todo $\alpha \in [0, 1]$:

$$\alpha x + (1 - \alpha)y \in C.$$

Geométricamente: *el segmento que une dos puntos de C está completamente contenido en C .*

Teorema (Intersección de convexos)

Si $C_1, C_2 \subseteq \mathbb{R}^n$ son convexos, entonces $C = C_1 \cap C_2$ también es convexo.

Demostración.

Sean $x, y \in C$. Entonces $x, y \in C_1$ y $x, y \in C_2$. Por convexidad de C_1 , $\alpha x + (1 - \alpha)y \in C_1$ para todo $\alpha \in [0, 1]$. Lo mismo para C_2 . Luego $\alpha x + (1 - \alpha)y \in C_1 \cap C_2 = C$. $\square$

Ejemplos: puntos, líneas, planos, semiespacios, bolas $B_r = \{x : \|x\|_2 \leq r\}$, elipsoides rellenos, conos convexos. *Politopos* $\mathcal{S} = \{x : Ax \leq b\}$ son convexos.

https://en.wikipedia.org/wiki/Convex_set

Funciones convexas y normas

Definición (Función convexa)

$f : \mathbb{R}^n \rightarrow \mathbb{R}$ es *convexa* si para todo x, y y $\alpha \in [0, 1]$:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y).$$

Convexidad estricta si la desigualdad es estricta para $x \neq y$.

Proposición (Normas son convexas)

Toda norma $\|\cdot\|$ es convexa: usando la desigualdad triangular,

$$\begin{aligned}\|\alpha x + (1 - \alpha)y\| &\leq \|\alpha x\| + \|(1 - \alpha)y\| \\ &= \alpha\|x\| + (1 - \alpha)\|y\|.\end{aligned}$$

Otras propiedades: $f + g$ convexas $\Rightarrow f + g$ convexa. f convexa $\Rightarrow -f$ cóncava. Composición afín $f(Ax + b)$ conserva convexidad. $\text{epi}(f) = \{(x, y) : y \geq f(x)\}$ es convexo $\Leftrightarrow f$ es convexa.

https://en.wikipedia.org/wiki/Convex_function

El teorema central de la optimización convexa

Teorema (Óptimo local = óptimo global)

Sea f una función convexa sobre un conjunto convexo $\mathcal{S}$. Entonces todo mínimo local de f sobre $\mathcal{S}$ es también un mínimo global. Si f es estrictamente convexa, el mínimo es único.

Prueba por contradicción.

Supongamos que x es mínimo local en $\mathcal{S}$, así que existe $\epsilon > 0$ tal que $f(z) \geq f(x)$ para todo $z \in \mathcal{S} \cap B_\epsilon(x)$. Supongamos además que existe $y \in \mathcal{S}$ con $f(y) < f(x)$.

Como $\mathcal{S}$ es convexo, todo punto del segmento $\{z = (1 - \alpha)x + \alpha y : \alpha \in [0, 1]\}$ es factible.

Eligiendo $\alpha_1 = \epsilon / \|y - x\|_2$ y $\alpha_2 = \alpha_1 / 2$, el punto $z = (1 - \alpha_2)x + \alpha_2 y$ cae dentro de la ϵ -bola.

Por convexidad y dado que $f(y) < f(x)$:

$$f(z) \leq \alpha_2 f(y) + (1 - \alpha_2) f(x) < f(x),$$

contradiciendo que x fuese mínimo local. □

Corolario

En LP y en mínimos cuadrados lineales todo óptimo local es global.

La desigualdad de Jensen

Teorema (Desigualdad de Jensen)

Sean $x_1, \dots, x_m \in \mathbb{R}^n$ y $\alpha_1, \dots, \alpha_m \geq 0$ con $\sum_{k=1}^m \alpha_k = 1$. Para toda f convexa:

$$f\left(\sum_{k=1}^m \alpha_k x_k\right) \leq \sum_{k=1}^m \alpha_k f(x_k).$$

Ejemplo (Aplicación probabilística)

Con $p(x) \geq 0$, $\int p(x) dx = 1$, la generalización a integrales da

$$f(\mathbb{E}[x]) \leq \mathbb{E}[f(x)].$$

En particular $(\mathbb{E}[x])^2 \leq \mathbb{E}[x^2]$ (tomando $f(t) = t^2$).

[figura pendiente]

Contenido: Interpretación geométrica: cualquier politopo formado por m puntos sobre la función está enteramente contenido en el epígrafe.

El gradiente: definición

Definición (Gradiente)

Para $f : \mathbb{R}^n \rightarrow \mathbb{R}$, el *gradiente* es

$$\nabla f(x) = \begin{bmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_n \end{bmatrix} \in \mathbb{R}^n.$$

Cada componente $\partial f / \partial x_k$ mide cuánto cambia f al variar x_k .

Aproximación de primer orden (Ec. (1.24)):

$$f(x) \approx f(x_0) + \nabla f(x_0)^\top (x - x_0).$$

Así, $\nabla f(x_0)^\top \Delta x$ aproxima el cambio de f ante un desplazamiento pequeño $\Delta x = x - x_0$.

[figura pendiente]

Contenido: El gradiente define el plano tangente en x_0 . (Brunton, Fig. 1.19.)

El gradiente: interpretación geométrica

Proposición (Dirección de máximo crecimiento)

El producto interior $\nabla f(x_0)^\top \Delta x$ se maximiza cuando Δx es paralelo a $\nabla f(x_0)$. Por tanto:

- ▶ $+\nabla f(x_0)$: *dirección de máximo crecimiento.*
- ▶ $-\nabla f(x_0)$: *dirección de máximo descenso local, base del descenso por gradiente (Cap. 2).*

Tangente y plano tangente: $\nabla f(x_0)$ generaliza la derivada escalar $f'(x_0)$ al caso vectorial: la derivada define la recta tangente en una variable; el gradiente define el *plano (o hiperplano) tangente* en varias.

Lema (Soporte desde abajo)

Para f diferenciable y convexa, el plano tangente en x_0 acota f desde abajo:

$$f(x) \geq f(x_0) + \nabla f(x_0)^\top (x - x_0) \quad \forall x.$$

Si existe x^ con $\nabla f(x^*) = 0$, entonces x^* es mínimo global.*

Hessiana y convexidad de segundo orden

Definición (Matriz Hessiana)

Para f dos veces continuamente diferenciable, la *Hessiana* es

$$H(x) = \nabla^2 f(x) = \begin{bmatrix} \partial^2 f / \partial x_1^2 & \cdots & \partial^2 f / \partial x_1 \partial x_n \\ \vdots & \ddots & \vdots \\ \partial^2 f / \partial x_n \partial x_1 & \cdots & \partial^2 f / \partial x_n^2 \end{bmatrix}.$$

Teorema (Condición de segundo orden para convexidad)

Una $f \in C^2$ es convexa si y sólo si $H(x) = \nabla^2 f(x) \succeq 0$ (semidefinida positiva) para todo x . Si $H(x) \succ 0$, f es estrictamente convexa.

Idea.

Expansión de Taylor de segundo orden:

$$f(x) \approx f(x_0) + \nabla f(x_0)^\top (x - x_0) + \frac{1}{2} (x - x_0)^\top \nabla^2 f(x_0) (x - x_0).$$

El término cuadrático es no negativo si y sólo si $H \succeq 0$.



Restricciones de igualdad: el Lagrangiano

Problema con restricciones de igualdad

$$\begin{array}{ll}\min_x & f(x) \\ \text{s.a.} & h(x) = 0.\end{array}$$

Idea clave: añadir una *penalización* $\delta_0(h(x))$ (vale 0 si $h(x) = 0$, $+\infty$ en otro caso) y suavizarla como $\lambda h(x)$:

$$\min_x \max_{\lambda} \underbrace{f(x) + \lambda h(x)}_{L(x, \lambda)}. \quad (\text{Ec. (1.30)})$$

A $L(x, \lambda)$ se le llama *Lagrangiano* y a λ el *multiplicador de Lagrange*.

El *problema dual* (Ec. (1.31)) se obtiene intercambiando el orden mín y máx: $\max_{\lambda} \min_x L(x, \lambda)$.

[figura pendiente]

Contenido: Plano tangente al conjunto factible en el óptimo. (Brunton, Fig. 1.21.)

Condición de optimalidad y ejemplos

Teorema (Condición necesaria de primer orden)

Si x^* resuelve el problema con restricción $h(x^*) = 0$ y $\nabla h(x^*) \neq 0$ (cualificación de regularidad), entonces existe $\lambda^* \in \mathbb{R}$ tal que

$$\begin{aligned}\nabla_x L(x^*, \lambda^*) &= \nabla f(x^*) + \lambda^* \nabla h(x^*) = 0, \\ \nabla_\lambda L(x^*, \lambda^*) &= h(x^*) = 0.\end{aligned}$$

Los gradientes de la objetivo y de la restricción activa son paralelos en el óptimo.

Ejemplo (Restricción activa)

mín $(x - 1)^2 + 1$ s.a. $x \leq 0$. El óptimo sin restricción es $x^* = 1$, pero la restricción lo empuja al borde: $x^* = 0$, $\lambda^* = 2$. Verificación: $\nabla f(x^*) = -2$, $\nabla g(x^*) = 1$, luego $\nabla f + \lambda \nabla g = 0 \Leftrightarrow \lambda^* = 2$.

Ejemplo (Restricción inactiva)

Misma formulación con $f(x) = (x + 1)^2 + 1$. El óptimo $x^* = -1$ ya satisface $g(x^*) < 0$, así que la restricción es inactiva y $\lambda^* = 0$.

KKT para restricciones mixtas

Problema general con restricciones mixtas

$$\begin{aligned} &\underset{x}{\text{mín}} f(x) \\ &\text{s.a. } g_i(x) \leq 0, \quad i = 1, \dots, m, \\ &\quad h_j(x) = 0, \quad j = 1, \dots, p. \end{aligned}$$

El Lagrangiano es $L(x, \lambda, \mu) = f(x) + \sum_i \lambda_i g_i(x) + \sum_j \mu_j h_j(x)$.

Teorema (Condiciones KKT (Karush–Kuhn–Tucker))

Bajo cualificaciones de regularidad (p.ej. Slater), existe (λ^, μ^*) con*

$$\begin{aligned} \nabla f(x^*) + \sum_i \lambda_i^* \nabla g_i(x^*) + \sum_j \mu_j^* \nabla h_j(x^*) &= 0, \\ g_i(x^*) &\leq 0, \quad h_j(x^*) = 0, \\ \lambda_i^* &\geq 0, \quad \lambda_i^* g_i(x^*) = 0 \quad (\text{complementariedad}). \end{aligned}$$

La complementariedad fuerza $\lambda_i^ = 0$ si la restricción es inactiva ($g_i(x^*) < 0$).*

Problemas inversos

Formulación general

Dado un *modelo directo* F y observaciones y_{obs} , buscamos parámetros x tales que $F(x) \approx y_{\text{obs}}$, es decir,

$$\min_x \|F(x) - y_{\text{obs}}\|_2^2.$$

Los datos son típicamente *parciales y ruidosos*, así que el problema suele ser *mal planteado* o *mal condicionado*. Las soluciones estándar combinan:

- ▶ *Regularización*: añadir $\|x\|^2$, $\|x\|_1$, etc.
- ▶ *Relajación*: sustituir normas no convexas (ℓ_0) por convexas (ℓ_1 , nuclear).
- ▶ *Priors bayesianos* (Cap. 7).

Aplicaciones: tomografía computarizada (CT), resonancia magnética (MRI), super-resolución, inversión sísmica, identificación de sistemas, diseño de perfiles aerodinámicos.

[figura pendiente]

Contenido: Esquema de un problema inverso: ajustar x para que $F(x)$ coincida con los datos observados.

Teoría de control

Lazo cerrado

La señal del sensor y se compara con la referencia r ; el error $\varepsilon = r - y$ alimenta al controlador, que produce la acción $u = k(x)$ sobre la planta:

$$\dot{x} = f(x, u), \quad u = k(x).$$

El objetivo de control óptimo se formula como

$$\min_{u(\cdot)} J(x, u) = \int_0^T \ell(x(t), u(t)) dt,$$

sujeto a la dinámica $\dot{x} = f(x, u)$ (que es una restricción diferencial, abordable con multiplicadores de Lagrange).

Casos clave:

- ▶ **LQR** (regulador cuadrático lineal): solución analítica con álgebra de Riccati.
- ▶ **MPC** (control predictivo por modelos): optimización en línea sobre un horizonte deslizante.
- ▶ **Reinforcement learning**: el controlador se aprende por interacción con el entorno.

[figura pendiente]

Aprendizaje automático (machine learning)

Optimización como motor del aprendizaje

Un modelo f_θ se entrena minimizando una *función de pérdida* sobre un conjunto de entrenamiento:

$$\min_{\theta} L(\theta) = \frac{1}{N} \sum_{j=1}^N \|y_j - f_\theta(x_j)\|^2 + \lambda R(\theta),$$

donde θ son los pesos, R es un regularizador (p.ej. $\|\theta\|^2$ o $\|\theta\|_1$) y λ controla la fuerza de regularización.

Retos típicos:

- ▶ *Alta dimensión*: θ con millones de parámetros $\Rightarrow$ SGD.
- ▶ *No convexidad*: muchos mínimos locales y puntos silla (Cap. 5).
- ▶ *Backpropagation* y diferenciación automática para $\nabla_{\theta} L$.

Fronteras activas: modelos generativos (LLMs, difusión), *physics-informed neural networks* (PINNs), aprendizaje por refuerzo profundo, ajuste de hiperparámetros como meta-optimización.

[figura pendiente]

Contenido: Entrenamiento de una red neuronal como problema de optimización.

Resumen

Anatomía: todo problema de optimización combina *función objetivo*, *variables de decisión* y *restricciones* (LP, QP, mínimos cuadrados como casos clave).

Convexidad: es la dicotomía más importante. Si f y el conjunto factible son convexos, *local* = *global*.

Gradientes: ∇f indica la dirección de máximo crecimiento; $-\nabla f$ define el descenso por gradiente. La *Hessiana* $H = \nabla^2 f$ caracteriza la curvatura local y, si $H \succeq 0$, la convexidad.

Restricciones: los *multiplicadores de Lagrange* convierten restricciones en términos del Lagrangiano; las *condiciones KKT* generalizan el cálculo a desigualdades con complementariedad.

Aplicaciones: problemas inversos (CT, MRI, sísmica), control óptimo (LQR, MPC), aprendizaje automático (entrenamiento de redes).

Referencias I



S. L. Brunton.

Optimization: A Bootcamp for Machine Learning, Inverse Problems, and Control.

Cambridge University Press, 2025 (borrador de libro).

Capítulo 1 (*Optimization Bootcamp*), secciones 1.1–1.5.



S. Boyd y L. Vandenberghe.

Convex Optimization.

Cambridge University Press, 2009.



J. Nocedal y S. J. Wright.

Numerical Optimization.

Springer, 1999.



D. P. Bertsekas.

Constrained Optimization and Lagrange Multiplier Methods.

Athena Scientific, 2014.

Referencias II



Y. Nesterov.

Lectures on Convex Optimization.

Springer, 2018.

Material complementario del autor:

`eigensteve.com/optimization` `github.com/dynamicslab/optimizationbook`